



Πολυτεχνική Σχολή
Τμήμα Μηχανικών Η/Υ & Πληροφορικής

ΕΞΟΡΥΞΗ ΔΕΔΟΜΕΝΩΝ ΚΑΙ ΑΛΓΟΡΙΘΜΟΙ ΜΑΘΗΣΗΣ

Εξηγήσιμη Τεχνητή Νοημοσύνη

Φίλιππος-Παρασκευάς Ζυγούρης
Α.Μ. 1084660

Πάτρα, 2025

Πίνακας Περιεχομένων

1. Εισαγωγή.....	4
1.1 Τοποθέτηση Προβλήματος.....	4
1.2 Σπουδαιότητα	5
1.3 Συνεισφορά.....	6
2. Θεμελιώδεις Έννοιες.....	8
2.1 Τεχνητή Νοημοσύνη.....	8
2.2 Μηχανική Μάθηση	8
2.3 Βαθιά Μάθηση	9
3. Προτεινόμενες τεχνικές.....	11
3.1 Θεωρητικό Πλαίσιο & Ταξινόμηση Μοντέλων	11
3.1.1 Διαφανή Μοντέλα (Transparent Models).....	11
3.1.2 Αδιαφανή Μοντέλα (Opaque/Black-Box Models).....	11
3.2 Ενοποιημένη Πλατφόρμα Εξηγήσεων: Υλοποίηση των Μεθοδολογιών	22
3.2.1 Omni XAI	22
3.2.2 Αρχιτεκτονική.....	23
3.3 Πείραμα «Δυνατότητα Προσομοίωσης»	23
3.3.1 Forward Simulation	24
3.3.2 Counterfactual Simulation.....	24
3.3.3 Αξιολόγηση Αλγοριθμικών Εξηγήσεων	25
3.3.4 Αποτελεσματικότητα Εξηγήσεων στην Κατανόηση	25
3.3.5 Υποκειμενική Ικανοποίηση ως Δείκτης Πραγματικής Αξίας Εξηγήσεων	26
4. Ατομικότητα και Συλλογικότητα.....	26
4.1 Η Υπεροχή των Υπολογιστών	26
4.2 Η Μοναδικότητα του Ανθρώπου	27
4.3 Συνεργασία Ανθρώπου και Μηχανής	28
4.4 Μαθαίνοντας από το Σκάκι.....	28
5. Τομείς Εφαρμογής.....	29
5.1 Επιχειρηματικές και Νομικές Διαστάσεις.....	29
5.1.1 Διαφάνεια, Λογοδοσία και Ενίσχυση Εμπιστοσύνης	29
5.1.2 Ανίχνευση Απάτης και Διαχείριση Κινδύνου	29
5.1.3 Νομικές Προκλήσεις και Ρυθμιστικό Πλαίσιο	30
5.2 Κρίσιμοι Τομείς.....	30
5.2.1 Βελτιώνοντας τη Διάγνωση και τη Φροντίδα Ασθενών.....	30
5.2.2 Ψηφιακός Μετασχηματισμός στο Μάρκετινγκ και τις Πωλήσεις.....	31
5.2.3 Εκπαίδευση και Ηθικές Προεκτάσεις.....	32
6. Δωδεκάλογος Επόμενων Βημάτων και Μελλοντικών Βελτιώσεων.....	32
6.1 Δημιουργία Εξηγήσεων για Νέους Τύπους Τεχνητής Νοημοσύνης	33

6.2 Αντιμετώπιση Περιορισμών	33
6.3 Αξιολόγηση Μεθόδων και Εξηγήσεων	34
6.4 Η Εννοιολογική Ασάφεια του Όρου «Εξηγήσιμο»	34
6.5 Πολυδιάστατη Εξηγησιμότητα	35
6.6 Εστίαση στον Άνθρωπο	36
6.7 Προσαρμογή σε διαφορετικούς αποδέκτες, πεδία και στόχους.....	36
6.8 Υπερβολική Πολυπλοκότητα	37
6.9 Μετριασμός των Αρνητικών Συνεπειών	37
6.10 Ενίσχυση του Κοινωνικού Αντίκτυπου	38
6.11 Επένδυση στην ΧΑΙ: Πυξίδα για την Πλοήγηση στο Μέλλον	38
6.12 Η Συνεργασία ως Κλειδί.....	39
7. Σύνοψη και Συμπέρασμα.....	40
7.1 Σύνοψη.....	40
7.2 Συμπέρασμα	41
8. Βιβλιογραφία.....	42

1. Εισαγωγή

1.1 Τοποθέτηση Προβλήματος

Την τελευταία δεκαετία, η αλματώδης πρόοδος της Τεχνητής Νοημοσύνης έχει μετατρέψει τους αλγορίθμους σε κρίσιμους καταλύτες στο κομμάτι της λήψης αποφάσεων σε τομείς όπως η οικονομία, η υγεία καθώς και σε άλλες νευραλγικές δραστηριότητες. Τα δεδομένα, που αποτελούν το νέο άρρηκτο φυσικό πόρο, συσσωρεύονται με πολύ μεγάλη ταχύτητα και χαρτογραφούν τον άνθρωπο σε ψηφιακά κομμάτια (bits) για την αιωνιότητα. Ωστόσο, παρά την υψηλή τους απόδοση, τα πλέον εξελιγμένα συστήματα ΤΝ, και κυρίως τα βαθιά νευρωνικά δίκτυα, χαρακτηρίζονται από αδιαφάνεια. Πιο συγκεκριμένα, λειτουργούν ουσιαστικά ως «μαύρα κουτιά», παρέχοντας αποτελέσματα χωρίς να αποκαλύπτουν τη λογική και τη διαδρομή που οδήγησε σε αυτές τις προβλέψεις. Επομένως, ο χρήστης βλέπει συχνά μόνο το τελικό αποτέλεσμα, το οποίο παρουσιάζεται ως ποσοστό βεβαιότητας, ενώ η διαδικασία λήψης της απόφασης παραμένει αδιευκρίνιστη, διευρύνοντας έτσι το χάσμα εμπιστοσύνης μεταξύ ανθρώπου και μηχανής.

Παράλληλα, η έλλειψη διαφάνειας έχει ήδη αναδείξει σημαντικούς κινδύνους στην καθημερινότητα. Στην ιατρική, για παράδειγμα, ένας αλγόριθμος που προτείνει μια χειρουργική επέμβαση χωρίς σαφή αιτιολόγηση μπορεί να θέσει πολλές ζωές σε κίνδυνο. Επιπλέον, στον χρηματοπιστωτικό τομέα, μια ανεξήγητη απόρριψη δανείου ενδέχεται να ενισχύσει κοινωνικές ανισότητες ή να παραβιάσει σημαντικά ρυθμιστικά πλαίσια, όπως είναι ο Γενικός Κανονισμός Προστασίας Δεδομένων (GDPR). Αντίστοιχα, στην αυτόνομη οδήγηση, μια ανεξήγητη επιλογή διαδρομής μπορεί να έχει επικίνδυνες συνέπειες και για τους επιβάτες και για τους πεζούς. Συμπερασματικά, παρά τις διαφορετικές εφαρμογές, ο κοινός κίνδυνος είναι οι αποφάσεις υψηλού αντίκτυπου που στερούνται πειστικών και κατανοητών εξηγήσεων.

Οι χρήστες, χωρίς να διαθέτουν επαρκή εξήγηση, βρίσκονται αντιμέτωποι με το εξής δίλημμα: είτε να αποδέχονται άκριτα τις αλγοριθμικές προτάσεις, είτε να τις απορρίπτουν χωρίς μια κατάλληλη αιτιολόγηση. Οι ρυθμιστικές αρχές δυσκολεύονται να επιβάλουν ουσιαστική λογοδοσία, καθώς αγνοούν τους εσωτερικούς μηχανισμούς λήψης αποφάσεων των μοντέλων, ενώ οι επιστήμονες δεδομένων στερούνται των απαραίτητων εργαλείων για την ανίχνευση σφαλμάτων ή «τυφλών σημείων». Κατά συνέπεια, η αδιαφάνεια των συστημάτων υπονομεύει τόσο την ασφάλεια όσο και τη βασική εμπιστοσύνη που απαιτείται για την υπεύθυνη και βιώσιμη ενσωμάτωση της ΤΝ στην κοινωνία.

1.2 Σπουδαιότητα

Η Εξηγήσιμη Τεχνητή Νοημοσύνη (ΧΑΙ) αναδύεται ως η απάντηση στο αδιέξοδο της αδιαφάνειας, φωτίζοντας τις μέχρι πρότινος αόρατες εσωτερικές διαδικασίες των αλγορίθμων και μετατρέποντας το μαύρο σε διαφανές κουτί. Η ΧΑΙ στοχεύει όχι απλώς στην παροχή εξηγήσεων, αλλά και στη διασφάλιση ότι αυτές θα είναι κατανοητές, χρησιμοποιώντας απλή γλώσσα, παραδείγματα και φιλικές προς τον χρήστη οπτικοποιήσεις. Σε αντίθεση με τα παραδοσιακά συστήματα που προσφέρουν μόνο μια πρόβλεψη χωρίς ερμηνεία, η ΧΑΙ αποκαλύπτει τη λογική πίσω από κάθε απόφαση, επιτρέποντας στους χρήστες να κατανοούν τόσο το τι προβλέπει το μοντέλο, όσο και το πώς και το γιατί καταλήγει σε κάθε συμπέρασμα. Αυτή η διαφάνεια που προκύπτει, μεταφράζεται σε πολλαπλά θεμελιώδη οφέλη για τα άτομα, τους οργανισμούς και τη κοινωνία συνολικά.

Πρώτα απ' όλα, η ΧΑΙ ενισχύει την εμπιστοσύνη και τη λογοδοσία. Όταν οι αλγόριθμοι κατορθώνουν να τεκμηριώσουν με σαφήνεια τα δεδομένα και τη λογική που οδήγησαν σε μια απόφαση, τα εμπλεκόμενα μέρη όπως οι γιατροί, οι τραπεζίκοι υπάλληλοι, οι εκπαιδευτικοί ή οι ρυθμιστικές αρχές έχουν τη δυνατότητα να ελέγξουν την ορθότητα του αποτελέσματος. Αυτό διευκολύνει αρκετά τον εντοπισμό μεροληψιών ή σφαλμάτων και ενισχύει την υπεύθυνη ανάληψη της τελικής απόφασης. Αντίθετα, χωρίς περαιτέρω εξηγήσεις, η υιοθέτηση των συστημάτων ΤΝ είναι συχνά επιφανειακή και παραμένει ευάλωτη στην αμφισβήτηση.

Επιπλέον, η ΧΑΙ λειτουργεί ως μηχανισμός πρόληψης σφαλμάτων υψηλού κόστους. Σε πεδία όπου ακόμα και ένα μεμονωμένο λάθος μπορεί να οδηγήσει σε ανεπανόρθωτες συνέπειες στην υγεία, τη χρηματοδότηση ή την αυτόνομη οδήγηση, η δυνατότητα να αναλύεται η αιτιολόγηση των αποφάσεων του μοντέλου επιτρέπει στον ειδικό να επαληθεύει τα αποτελέσματα και να παρεμβαίνει εγκαίρως, αποτρέποντας έτσι επικίνδυνες ή λανθασμένες ενέργειες.

Εξίσου σημαντικό είναι ότι η ΧΑΙ διευκολύνει τη συμμόρφωση με το διαρκώς αυστηρότερο ρυθμιστικό και ηθικό πλαίσιο. Νομοθετικές απαιτήσεις όπως ο Γενικός Κανονισμός Προστασίας Δεδομένων (GDPR) και οι αρχές της αξιόπιστης ΤΝ απαιτούν πλέον το δικαίωμα σε τεκμηριωμένη εξήγηση για κάθε αυτοματοποιημένη απόφαση που επηρεάζει άμεσα τον πολίτη. Η ΧΑΙ έρχεται να καλύψει αυτό το κενό, προσφέροντας διαφανείς και ορθά αιτιολογημένες εξηγήσεις, διασφαλίζοντας τη νομική συμμόρφωση και την προστασία των θεμελιωδών δικαιωμάτων.

Πέρα από αυτά τα άμεσα οφέλη, η εξηγησιμότητα μετασχηματίζει ουσιαστικά τη σχέση μεταξύ ανθρώπου και μηχανής. Ο τελικός χρήστης αποκτά τη δυνατότητα διαδραστικής διερεύνησης αιτίων και σεναρίων τύπου «τι θα γινόταν αν...», λαμβάνοντας πρακτικές κατευθύνσεις για βελτίωση. Ταυτόχρονα, η ΧΑΙ επιταχύνει την καινοτομία, καθώς διευκολύνει τους ερευνητές και τους μηχανικούς να εντοπίζουν τι έχει διδαχθεί πραγματικά το μοντέλο, πού αποτυγχάνει και πώς μπορεί να βελτιωθεί. Τέλος, η ΧΑΙ

καλλιεργεί νέες συνεργατικές δυναμικές, όπου η υπολογιστική ισχύς και η ικανότητα ανάλυσης των μοντέλων TN συνδυάζονται με την ανθρώπινη εμπειρία, τη κρίση και τις αξίες. Αυτός ο συνδυασμός, αποδεδειγμένα, οδηγεί σε ανώτερες και πιο αξιόπιστες αποφάσεις από ό,τι μπορούν να επιτύχουν μεμονωμένα οι άνθρωποι ή οι μηχανές.

Συνοψίζοντας, σε έναν κόσμο που εξαρτάται ολοένα και περισσότερο από αυτοματοποιημένες διαδικασίες, η Εξηγήσιμη Τεχνητή Νοημοσύνη δεν αποτελεί απλώς μια τεχνολογική εξέλιξη, αλλά βασική προϋπόθεση για την υλοποίηση περισσότερο αξιόπιστων, δίκαιων και ασφαλών λύσεων. Επομένως, όπως η έγκαιρη διάγνωση σώζει ζωές στην ιατρική, έτσι και η ΧΑΙ διασφαλίζει τη «ζωή» κάθε απόφασης, διασφαλίζοντας τον κάθε αλγόριθμο να λειτουργεί με υπευθυνότητα, διαφάνεια και προς όφελος όλης της κοινωνίας.

1.3 Συνεισφορά

Ο σκοπός της παρούσας ερευνητικής αναφοράς, επομένως, είναι η ανάδειξη και ο συντονισμός επιλεγμένων θεωρητικών και πρακτικών προσεγγίσεων στην Εξηγήσιμη Τεχνητή Νοημοσύνη, με απώτερο στόχο τη συστηματική μετάβαση από τα παραδοσιακά «μαύρα κουτιά» σε πιο διαφανείς, αξιόπιστες και ανθρωποκεντρικές λύσεις. Βασιζόμενη σε μία ακόμα πιο διεξοδική ανάλυση του πλούσιου υλικού των δημοσιεύσεων, η μελέτη αυτή προτείνει ένα σύνολο καινοτόμων στρατηγικών που αναμένεται να βελτιώσουν ουσιαστικά τον τρόπο με τον οποίο οι εξηγήσεις παράγονται, κατανοούνται και εφαρμόζονται στην πράξη.

Στο πλαίσιο αυτό, προτείνεται η ανάπτυξη πολυεπίπεδων αφηγηματικών εξηγήσεων, οι οποίες προσαρμόζονται δυναμικά στο γνωστικό υπόβαθρο και τις ανάγκες του εκάστοτε χρήστη. Ιδιαίτερη έμφαση δίνεται στην ενσωμάτωση εννοιοκεντρικών και αντιπαραδειγματικών (counterfactual) τεχνικών, ώστε οι παραγόμενες εξηγήσεις να είναι όχι μόνο αιτιακά κατανοητές, αλλά και πρακτικά χρήσιμες και εφαρμόσιμες για τον τελικό χρήστη. Ενδεικτικά παραδείγματα αποτελούν η MACE για τους πίνακες και το Polyjuice για το κείμενο. Οι προσεγγίσεις αυτές ενισχύουν την causability, παρέχοντας όχι μόνο το «πώς» αλλά και το «τι πρέπει να αλλάξει» για να επιτευχθεί ένα διαφορετικό αποτέλεσμα.

Παράλληλα, η μελέτη εισάγει σημαντικές βελτιώσεις στις υπάρχουσες στρατηγικές ΧΑΙ, προτείνοντας τον συνδυασμό model-agnostic και model-specific μεθόδων (όπως PDP, LIME, SHAP, Grad-CAM) σε μια ενοποιημένη ροή, γεγονός το οποίο επιδιώκει να ελαχιστοποιήσει την αστάθεια και να ενισχύσει την αξιοπιστία των εξηγήσεων. Επιπλέον, προτείνεται ο εμπλουτισμός των τεχνικών ανάλυσης σημασίας χαρακτηριστικών με μέτρα αβεβαιότητας και νέα μεταμοντέρνα κριτήρια ποιότητας, όπως η simulatability και η causability, τα οποία ενισχύουν την εμπιστοσύνη και τη διαφάνεια, κυρίως σε ρυθμιζόμενα περιβάλλοντα όπως η ιατρική διάγνωση και το GDPR.

Ένα ακόμη σημαντικό στοιχείο της συνεισφοράς είναι η συγχώνευση ετερογενών προσεγγίσεων σε μια ολιστική αρχιτεκτονική. Ειδικότερα, υιοθετείται ένα τετραεπίπεδο πλαίσιο τύπου Omni XAI, το οποίο περιλαμβάνει τυποποίηση δεδομένων, αυτόματη επιλογή του κατάλληλου explainer, ενοποιημένους μηχανισμούς οπτικοποίησης, καθώς και διαδραστικά dashboards για τον χρήστη. Παράλληλα, διασυνδέονται αιτιακά γραφικά μοντέλα, γενετικοί αλγόριθμοι (όπως ο MOCE) και τεχνικές μηχανιστικής ερμηνευσιμότητας, δημιουργώντας με αυτό το τρόπο πολυδιάστατες εξηγήσεις που λαμβάνουν υπόψη την ασφάλεια, τη δικαιοσύνη, τη λογοδοσία και τη συνολική αξιοπιστία.

Στο ίδιο πλαίσιο, η εργασία εισηγείται νέα κριτήρια ποιότητας (simulatability, causability), ποσοτικοποιημένη αβεβαιότητα και εισάγει ένα πιο ανθρωποκεντρικό πλαίσιο αξιολόγησης που μετράει την αξία των εξηγήσεων μέσω δοκιμών forward και counterfactual simulation σε ρεαλιστικά σενάρια λήψης αποφάσεων. Η ενοποίηση αιτιακών γραφικών μοντέλων, γενετικών αλγορίθμων (π.χ. MOCE) και μηχανιστικής ερμηνευσιμότητας επιτρέπει τη δημιουργία πολυδιάστατων εξηγητικών αναπαραστάσεων που καλύπτουν ταυτόχρονα ασφάλεια, δικαιοσύνη, λογοδοσία και συνολική αξιοπιστία, ιδίως σε ρυθμιζόμενα περιβάλλοντα όπως η ιατρική διάγνωση ή η συμμόρφωση με το GDPR.

Η συμβολή της παρούσας μελέτης ολοκληρώνεται με την πρόταση ενός πλαισίου αξιολόγησης που εστιάζει στον άνθρωπο. Η υιοθέτηση μετρικών προσομοιωσιμότητας (forward & counterfactual simulation) λειτουργεί ως αντικειμενικός δείκτης της πραγματικής αξίας κάθε εξήγησης. Επιπλέον, προτείνεται η διεπιστημονική ερευνητική μεθοδολογία με ενεργή συμμετοχή τελικών χρηστών, κοινωνικών επιστημόνων και ειδικών στη διεπαφή ανθρώπου-υπολογιστή (HCI), ώστε να μετρηθεί η επίδραση των εξηγήσεων σε πραγματικά σενάρια λήψης αποφάσεων.

Συνολικά, η μελέτη αυτή μετασχηματίζει τις εξηγήσεις από στατικές, ad-hoc αναλύσεις σε βιώσιμα, εξατομικευμένα και δράσιμα εργαλεία υποστήριξης αποφάσεων, ενισχύοντας ουσιαστικά την εμπιστοσύνη, τη διαφάνεια και την αποτελεσματικότητα των συστημάτων τεχνητής νοημοσύνης. Τέλος, συμβάλλει ουσιαστικά στον χώρο της Εξηγήσιμης Τεχνητής Νοημοσύνης, καθώς προτείνει ένα συνεκτικό πλάνο που μετασχηματίζει τις εξηγήσεις από στατικές τεχνικές αναλύσεις σε εξατομικευμένα και πολυδιάστατα εργαλεία υποστήριξης αποφάσεων. Αξιοποιώντας τη σύνθεση και την καινοτομία, οι προτεινόμενες κατευθύνσεις έχουν τη δυναμική να αναβαθμίσουν την εμπιστοσύνη, τη λογοδοσία και την αποτελεσματικότητα των συστημάτων τεχνητής νοημοσύνης.

2. Θεμελιώδεις Έννοιες

Προτού όμως εξεταστούν αναλυτικά οι τεχνικές, τα εργαλεία και τα μεθοδολογικά πλαίσια της ΧΑΙ, είναι αναγκαίο να παρουσιαστούν με σαφήνεια οι βασικές έννοιες και τα θεμελιώδη δομικά στοιχεία που διέπουν τον χώρο της Τεχνητής Νοημοσύνης, θέτοντας το θεωρητικό πλαίσιο για την ερμηνεία των μοντέλων και των αποφάσεών τους. Μόνο μέσα από μια βαθύτερη κατανόηση του πώς λειτουργεί η ΤΝ από τα κλασικά συστήματα μέχρι τα πιο σύγχρονα γενετικά μοντέλα, είναι εφικτό να αναγνωριστούν τόσο οι δυνατότητες όσο και οι περιορισμοί αυτών των συστημάτων.

2.1 Τεχνητή Νοημοσύνη

Η Τεχνητή Νοημοσύνη αποτελεί ένα ευρύ φάσμα τεχνολογιών που επιδιώκουν να καταστήσουν τους υπολογιστές «έξυπνους», ικανούς δηλαδή να εκτελούν εργασίες που παραδοσιακά χρειάζονται ανθρώπινη νοημοσύνη. Σύμφωνα με το Oxford Dictionary, η ΤΝ είναι «η θεωρία και η ανάπτυξη συστημάτων ικανών να εκτελούν εργασίες που απαιτούν ανθρώπινη νοημοσύνη», ενώ στη διατύπωση του Stanford χαρακτηρίζεται ως «η επιστήμη και η μηχανική της δημιουργίας μηχανών που αντιλαμβάνονται, αιτιολογούν και μαθαίνουν από το περιβάλλον τους». Σε μια τυπική ροή τεχνητής νοημοσύνης, ακολουθούνται τρία βασικά στάδια.

Αρχικά συλλέγονται και εισάγονται τα δεδομένα (όπως, για παράδειγμα, η εικόνα μιας γάτας). Στη συνέχεια, αυτά επεξεργάζονται και αναλύονται από το μοντέλο ή τον αλγόριθμο που ανακαλύπτει συσχετίσεις και μοτίβα, κατανοώντας πολύπλοκες, μη γραμμικές σχέσεις, κάτι που υπερβαίνει τις παραδοσιακές στατιστικές τεχνικές. Τέλος παράγεται η έξοδος, όπως για παράδειγμα μια πρόβλεψη ή ταξινόμηση (π.χ. «Γάτα με 95% βεβαιότητα»). Ωστόσο, σε αυτό το στάδιο, το σύστημα συχνά δεν παρέχει καμία αιτιολόγηση για το πώς κατέληξε σε αυτό το αποτέλεσμα, αφήνοντας έτσι τη διαδικασία λήψης απόφασης αδιαφανή. Επομένως, ο στόχος της ΤΝ δεν είναι να αντικαταστήσει την ανθρώπινη τεχνογνωσία, αλλά να την ενισχύσει, παρέχοντας πρόσθετη αναλυτική ισχύ και υποστηρίζοντας τη λήψη τεκμηριωμένων αποφάσεων.

2.2 Μηχανική Μάθηση

Σε μια εποχή όπου τα δεδομένα διαδραματίζουν καθοριστικό ρόλο, η μηχανική μάθηση αξιοποιεί αυτή τη δύναμη για να επιτρέψει στα συστήματα να μαθαίνουν και να εξελίσσονται μέσα από την εμπειρία. Αυτός ο καινοτόμος τομέας, που βρίσκεται στην καρδιά της τεχνητής νοημοσύνης, εστιάζει στην ανάπτυξη αλγορίθμων με ένα άνευ προηγουμένου επίπεδο αυτοματισμού, ενδυναμώνοντας τα ευφυή συστήματα να αντιμετωπίζουν πολύπλοκα προβλήματα με ελάχιστη έως καθόλου ανθρώπινη καθοδήγηση. Μαθαίνοντας από προηγούμενες ανόμοιες ροές δεδομένων και παρατηρήσεων, με την πάροδο του χρόνου, αυτοί οι αλγόριθμοι πραγματοποιούν

προβλέψεις με βάση τη συσσωρευμένη εμπειρία τους, μοντελοποιώντας τα δυναμικά φαινόμενα του πραγματικού κόσμου και αποκαλύπτοντας μοτίβα, που είναι αόρατα με γυμνό μάτι.

Ένα χαρακτηριστικό παράδειγμα αποτελεί μια εφαρμογή αναγνώρισης γάτας. Αρχικά, συλλέγονται χιλιάδες φωτογραφίες γάτας από ποικίλα περιβάλλοντα, οι οποίες ετικετοποιούνται κατάλληλα (π.χ. ως «γάτα» ή με συγκεκριμένη ράτσα), και στη συνέχεια ο αλγόριθμος μηχανικής μάθησης εκπαιδεύεται να συσχετίζει τα χαρακτηριστικά των εικόνων με τις αντίστοιχες ετικέτες. Το αποτέλεσμα είναι ένα μοντέλο ικανό να πραγματοποιεί γενικεύσεις σε άγνωστα δεδομένα, ώστε ο τελικός χρήστης να μπορεί να εισάγει μια νέα φωτογραφία και να λαμβάνει πρόβλεψη, όπως «Γάτα με 97% βεβαιότητα».

2.3 Βαθιά Μάθηση

Η Βαθιά Μάθηση αποτελεί μια εξειδικευμένη μορφή μηχανικής μάθησης, η οποία αξιοποιεί πολυστρωματικά νευρωνικά δίκτυα για να μιμηθεί, σε βασικό επίπεδο, την ικανότητα του ανθρώπινου εγκεφάλου να εξάγει σύνθετες πληροφορίες από τεράστια και ετερογενή σύνολα δεδομένων. Τα τεχνητά νευρωνικά δίκτυα εμπνέονται από τα βιολογικά νευρωνικά δίκτυα, τα οποία αποτελούνται από διασυνδεδεμένες μονάδες επεξεργασίας, τους τεχνητούς νευρώνες, που συνεργάζονται ως ομάδα ανταλλάσσοντας πληροφορίες. Παρότι μιμούνται τη δομή του εγκεφάλου, οι τεχνητοί νευρώνες παραμένουν απλοί ως προς τη λειτουργία τους και δεν αγγίζουν την πολυπλοκότητα και την αναλυτική ικανότητα των βιολογικών νευρικών κυττάρων, καθώς αυτοί αναλύουν στιγμιαία χιλιάδες λεπτομέρειες για να αποκωδικοποιήσουν νέα αντικείμενα και να τα τοποθετήσουν στο ίδιο πλαίσιο αναφοράς.

Για να λειτουργήσουν αποτελεσματικά, τα νευρωνικά δίκτυα χρειάζεται να εκπαιδευτούν κατάλληλα. Σε μια τυπική αρχιτεκτονική βαθιάς μάθησης, τα δεδομένα εισάγονται αρχικά στο στρώμα εισόδου (όπως τα pixels μιας εικόνας), περνούν μέσα από διαδοχικά κρυφά στρώματα όπου ανιχνεύονται όλο και πιο σύνθετα χαρακτηριστικά, ενώ τα βάρη και οι παράμετροι προσαρμόζονται με στόχο την ελαχιστοποίηση του σφάλματος μεταξύ των προβλέψεων και των επιθυμητών αποτελεσμάτων. Το τελικό στρώμα παράγει την έξοδο και την τελική πρόβλεψη, π.χ. αν πρόκειται για γάτα ή όχι. Σε αντίθεση με τους παραδοσιακούς αλγορίθμους που απαιτούν χειροκίνητο σχεδιασμό κάθε βήματος, τα νευρωνικά δίκτυα μαθαίνουν αυτόματα από τα δεδομένα, καθιστώντας δυνατή την επίλυση πολύπλοκων προβλημάτων.

Παρά τη μεγάλη τους επιτυχία, η εσωτερική λειτουργία των βαθιών δικτύων παραμένει συχνά αδιαφανής ακόμη και στους ίδιους τους δημιουργούς τους. Για τον λόγο αυτό, γίνεται μια ευρεία χρήση προεκπαιδευμένων νευρωνικών δικτύων που έχουν ήδη βελτιστοποιηθεί για συγκεκριμένα είδη δεδομένων, ενώ η εκπαιδευτική διαδικασία θυμίζει σε πολλά σημεία την εκπαίδευση των ατόμων σε συγκεκριμένες δραστηριότητες χωρίς την πλήρη κατανόηση των υποκείμενων νευρολογικών διεργασιών, θεωρώντας ότι η εκπαιδευτική διαδικασία θα είναι αποτελεσματική εάν εκτελεστεί σωστά.

2.4 Μετάβαση στην Εξηγήσιμη Τεχνητή Νοημοσύνη

Η ανάγκη για εξηγησιμότητα στην τεχνητή νοημοσύνη έχει καταστεί πιο επιτακτική από ποτέ, καθώς τα σύγχρονα μοντέλα, παρά τις εντυπωσιακές τους επιδόσεις, αποτυγχάνουν να παρέχουν κατανοητές αιτιολογήσεις για τις αποφάσεις τους. Σε αντίθεση με έναν άνθρωπο που μπορεί να εξηγήσει πώς αναγνώρισε μια γάτα σε μια εικόνα, τα συστήματα ΤΝ συχνά περιορίζονται σε μια απλή απάντηση χωρίς επαρκή αιτιολόγηση. Αυτό μπορεί να είναι αποδεκτό σε καθημερινές εφαρμογές χαμηλού ρίσκου, όμως σε τομείς όπως η ιατρική διάγνωση, η οικονομική αξιολόγηση ή η αυτόνομη οδήγηση, η έλλειψη διαφάνειας δημιουργεί σημαντικά ερωτήματα αξιοπιστίας και ασφάλειας.

Χαρακτηριστικό παράδειγμα παραπλανητικής συμπεριφοράς αποτελεί η έρευνα στην οποία ένα νευρωνικό δίκτυο αναγνώρισε με βεβαιότητα άσχετες εικόνες ως κιθάρες ή πιγκουίνους, βασιζόμενο σε επιφανειακά μοτίβα που δεν ήταν αντιληπτά από τον ανθρώπινο παρατηρητή. Αυτές οι περιπτώσεις αναδεικνύουν τον κίνδυνο των συστημάτων να λαμβάνουν αποφάσεις με βάση αδιάφανους ή εσφαλμένους συσχετισμούς, με αποτέλεσμα να προκαλούνται δυνητικά σοβαρές επιπτώσεις όταν πρόκειται για κρίσιμες αποφάσεις.

Η μετάβαση προς την Εξηγήσιμη Τεχνητή Νοημοσύνη έρχεται να καλύψει αυτό το κενό, εισάγοντας τεχνικές και εργαλεία που καθιστούν διαφανή τη λογική πίσω από κάθε απόφαση του μοντέλου. Σε αντίθεση με τα συμβατικά συστήματα που λειτουργούν ως «μαύρα κουτιά» και παρέχουν μόνο το τελικό αποτέλεσμα χωρίς καμία αιτιολόγηση, προκαλώντας αβεβαιότητα και δισταγμό στους χρήστες, το ΧΑΙ επιδιώκει να προσφέρει σαφείς, τεκμηριωμένες εξηγήσεις και να επισημαίνει τα όρια αξιοπιστίας των μοντέλων, ενισχύοντας έτσι την εμπιστοσύνη στη χρήση της τεχνητής νοημοσύνης. Διαφανή μοντέλα, όπως για παράδειγμα, τα Decision Trees, διευκολύνουν την κατανόηση των αποφάσεων, ενώ για τα πιο σύνθετα και αδιαφανή μοντέλα εφαρμόζονται προχωρημένες τεχνικές, όπως οι model-agnostic μέθοδοι (LIME, SHAP) και οι model-specific (Grad-CAM), που παρέχουν είτε τοπική είτε εξειδικευμένη ερμηνευσιμότητα. Επιπλέον, τα αντιπαραδείγματα (counterfactuals) όπως τα DiCE και τα MOCE συμβάλλουν στον εντοπισμό των μεταβλητών που χρειάζονται αλλαγή για την επίτευξη διαφορετικού αποτελέσματος. Συνολικά, η υιοθέτηση της ΧΑΙ δεν αποτελεί πλέον απλώς μια επιστημονική εξέλιξη, αλλά θεμελιώδη προϋπόθεση για μια πιο υπεύθυνη εφαρμογή της τεχνητής νοημοσύνης.

3. Προτεινόμενες τεχνικές

3.1 Θεωρητικό Πλαίσιο & Ταξινόμηση Μοντέλων

3.1.1 Διαφανή Μοντέλα (Transparent Models)

Τα διαφανή μοντέλα είναι συστήματα των οποίων ο εσωτερικός μηχανισμός λειτουργίας είναι άμεσα κατανοητός και ανιχνεύσιμος, επιτρέποντας στον χρήστη να εξηγήσει με σαφήνεια πώς προκύπτει η τελική απόφαση χωρίς την ανάγκη εξωτερικών εργαλείων. Χαρακτηριστικά παραδείγματα διαφανών μοντέλων αποτελούν τα tree-based μοντέλα, όπως τα Decision Trees, όπου κάθε απόφαση λαμβάνεται ακολουθώντας μια συγκεκριμένη διαδρομή από τη ρίζα μέχρι ένα φύλλο του δέντρου, λαμβάνοντας υπόψη διαδοχικά κριτήρια που εφαρμόζονται στα χαρακτηριστικά των δεδομένων. Αυτό δίνει τη δυνατότητα στον χρήστη να παρακολουθήσει βήμα προς βήμα τη λογική του μοντέλου και να διαπιστώσει πώς κάθε χαρακτηριστικό συμβάλλει στο τελικό αποτέλεσμα.

Επιπλέον, ένα ακόμα παράδειγμα αποτελούν τα μοντέλα K-Nearest Neighbors (KNN), τα οποία στηρίζονται στην αναζήτηση των k πιο κοντινών παραδειγμάτων από το εκπαιδευτικό σύνολο, με τη χρήση κατάλληλης μετρικής απόστασης, όπως η ευκλείδεια. Ο χρήστης μπορεί να διαπιστώσει ποια παραδείγματα χρησιμοποιήθηκαν για την πρόβλεψη και, συγκρίνοντας τα χαρακτηριστικά τους με τη νέα παρατήρηση, να κατανοήσει με μεγαλύτερη σαφήνεια τους παράγοντες που επηρέασαν την τελική απόφαση, εξασφαλίζοντας μια πλήρη διαφάνεια στη διαδικασία λήψης αποφάσεων.

3.1.2 Αδιαφανή Μοντέλα (Opaque/Black-Box Models)

Τα αδιαφανή μοντέλα περιλαμβάνουν πιο πολύπλοκα συστήματα, όπως τα Random Forest και τα Support Vector Machines (SVM), στα οποία η εσωτερική λειτουργία δεν είναι άμεσα κατανοητή από τον χρήστη. Τα Random Forest αποτελούνται από μεγάλο πλήθος δέντρων απόφασης που λειτουργούν ταυτόχρονα και συνδυάζουν τις επιμέρους προβλέψεις τους για να παράγουν το τελικό αποτέλεσμα. Παρότι κάθε μεμονωμένο δέντρο ακολουθεί μια διαφανή λογική, ο συνδυασμός εκατοντάδων ή χιλιάδων τέτοιων δέντρων καθιστά σχεδόν αδύνατη την ανάλυση της ακριβούς συμβολής κάθε χαρακτηριστικού στο συνολικό αποτέλεσμα.

Αντίστοιχα, τα SVM χρησιμοποιούν μαθηματικά όρια, γνωστά ως υπερεπιφάνειες (hyperplanes), για να διαχωρίσουν τις κατηγορίες σε υψηλές διαστάσεις. Σε απλά προβλήματα το όριο μπορεί να απεικονιστεί ως γραμμή ή επίπεδο, όμως σε πραγματικά δεδομένα η πολυδιάστατη υπερεπιφάνεια δεν είναι εύκολα ερμηνεύσιμη. Επομένως, η τελική απόφαση βασίζεται σε συγκεκριμένα παραδείγματα, τα λεγόμενα support vectors, που καθορίζουν τη θέση της υπερεπιφάνειας. Εξαιτίας αυτής της πολυπλοκότητας, τα αδιαφανή μοντέλα απαιτούν τη χρήση πιο εξειδικευμένων τεχνικών ερμηνείας (post-hoc

explainability) ώστε να καταστεί εφικτή η κατανόηση και η ερμηνεία των αποφάσεων τους.

3.1.2.1 Model-Agnostic Τεχνικές

Οι model-agnostic τεχνικές αποτελούν μεθόδους εξήγησης που εφαρμόζονται ανεξάρτητα από την εσωτερική δομή του μοντέλου. Η κύρια ισχύς τους έγκειται στο γεγονός ότι λειτουργούν απευθείας στα δεδομένα εκπαίδευσης, αναλύοντας τη σχέση μεταξύ των χαρακτηριστικών εισόδου και της εξόδου χωρίς να απαιτείται γνώση του εσωτερικού μηχανισμού του μοντέλου. Αυτή η ευελιξία επιτρέπει τη σύγκριση εξηγήσεων μεταξύ διαφορετικών αλγορίθμων, διευκολύνοντας την αξιολόγηση της συμπεριφοράς πολλαπλών συστημάτων. Ωστόσο, οι τοπικές εξηγήσεις που παράγουν μπορεί να μην αντικατοπτρίζουν πάντα με ακρίβεια τη συνολική λειτουργία του μοντέλου.

Αυτές οι μέθοδοι διακρίνονται σε δύο κατηγορίες. Από τη μία πλευρά, είναι τα γραφήματα μερικής εξάρτησης (Partial Dependence Plots, PDP) και η ανάλυση ευαισθησίας Morris, τα οποία παρέχουν καθολική ερμηνευσιμότητα παρουσιάζοντας την επίδραση ενός ή δύο χαρακτηριστικών στην πρόβλεψη. Από την άλλη, είναι τα surrogate models, τα οποία εκπαιδεύονται με σκοπό να προσεγγίσουν τοπικά τις προβλέψεις του αρχικού black-box μοντέλου, προσφέροντας εξηγήσεις για μεμονωμένες προβλέψεις, με χαρακτηριστικά παραδείγματα τα LIME, SHAP και L2X.

3.1.2.1.1 LIME

Η μέθοδος LIME (Local Interpretable Model-agnostic Explanations) ανήκει στην κατηγορία των τεχνικών εκτίμησης της σημασίας χαρακτηριστικών και παρέχει περισσότερες πληροφορίες σχετικά με το πώς το μοντέλο χρησιμοποιεί συγκεκριμένα χαρακτηριστικά για να καταλήξει σε μια πρόβλεψη. Συγκεκριμένα, δημιουργεί μικρές παραλλαγές γύρω από το εξεταζόμενο παράδειγμα και παρατηρεί πώς μεταβάλλεται η πρόβλεψη του μοντέλου σε κάθε περίπτωση, προσαρμόζοντας στη συνέχεια ένα απλό και ερμηνεύσιμο μοντέλο (συνήθως γραμμικό) για να αναδείξει ποια χαρακτηριστικά συνέβαλαν περισσότερο στην τελική απόφαση. Κάθε χαρακτηριστικό λαμβάνει ένα βάρος που αντικατοπτρίζει τη συνεισφορά του, το οποίο υπολογίζεται μέσω μιας συνάρτησης ομοιότητας που λαμβάνει υπόψη την απόσταση των παραλλαγμένων δειγμάτων από το αρχικό.

Επίσης, η LIME είναι ιδιαίτερα χρήσιμη για εξηγήσεις σε tabular δεδομένα, κείμενο και εικόνες. Για παράδειγμα, αναδεικνύει τα πιο σημαντικά χαρακτηριστικά που οδηγούν σε μια πρόβλεψη, εντοπίζει λέξεις-κλειδιά σε κείμενο και υποδεικνύει περιοχές εικόνας που καθορίζουν την απόφαση του μοντέλου. Παρά τα σημαντικά πλεονεκτήματα διαφάνειας, η LIME παρουσιάζει και μερικούς περιορισμούς, καθώς υποθέτει τοπική γραμμικότητα (που δεν ισχύει πάντα), είναι υπολογιστικά απαιτητική λόγω των πολλαπλών δειγμάτων που δημιουργεί για κάθε εξήγηση, και ενδέχεται να εμφανίζει αστάθεια μεταξύ εκτελέσεων, χωρίς να εντοπίζει πάντα πιθανές μεροληψίες ή ευπάθειες του μοντέλου.

3.1.2.1.2 PDPs

Τα PDPs (Partial Dependence Plots) αποτελούν μια καθολική μέθοδο ερμηνείας που απεικονίζει τη μέση επίδραση ενός συγκεκριμένου χαρακτηριστικού στην πρόβλεψη ενός μοντέλου, απομονώνοντας την επίδραση των υπολοίπων χαρακτηριστικών. Με αυτό το τρόπο, προσφέρουν μια ξεκάθαρη εικόνα για το πώς μια μεταβλητή επηρεάζει το τελικό αποτέλεσμα, ανεξάρτητα από την εσωτερική λειτουργία του μοντέλου. Για την κατασκευή ενός PDP, το μοντέλο εκπαιδεύεται κανονικά και το αρχικό σύνολο δεδομένων αναπαράγεται τόσες φορές όσες είναι οι μοναδικές τιμές του χαρακτηριστικού ενδιαφέροντος, με κάθε αντίγραφο να λαμβάνει μια συγκεκριμένη τιμή για το χαρακτηριστικό αυτό, ενώ τα υπόλοιπα χαρακτηριστικά διατηρούνται σταθερά.

Στη συνέχεια, το μοντέλο προβλέπει την έκβαση για κάθε νέο σετ δεδομένων και τα αποτελέσματα υπολογίζονται ως μέσος όρος για κάθε μοναδική τιμή, σχηματίζοντας ένα γράφημα που αποτυπώνει την επίδραση του χαρακτηριστικού στη συνολική πρόβλεψη (π.χ. πώς οι ώρες εργασίας επηρεάζουν την πρόβλεψη εισοδήματος). Τα PDPs είναι ιδιαίτερα χρήσιμα για την κατανόηση της παγκόσμιας συμπεριφοράς των χαρακτηριστικών και τον εντοπισμό μη γραμμικών σχέσεων, ενώ επιτρέπουν και τη σύγκριση της σημασίας ανάμεσα σε διαφορετικές μεταβλητές. Ωστόσο, προϋποθέτουν ανεξαρτησία μεταξύ των χαρακτηριστικών και ενδέχεται να οδηγήσουν σε παραπλανητικά συμπεράσματα σε περιπτώσεις ισχυρής συσχέτισης μεταξύ τους.

3.1.2.1.3 Decision Boundary

Η μέθοδος Decision Boundary ανήκει στην κατηγορία της διερεύνησης του λανθάνοντος χώρου (Latent Space Traversal) και αποσκοπεί στο να κατανοήσει πώς αλλάζει η συμπεριφορά ενός μοντέλου καθώς μεταβάλλονται τα χαρακτηριστικά της εισόδου. Αν και αυτού του είδους οι τεχνικές έχουν εφαρμοστεί κυρίως σε μοντέλα υπολογιστικής όρασης, εδώ παρουσιάζεται μια καινοτόμος προσέγγιση για δεδομένα κειμένου και πινάκων. Η μέθοδος αυτή καταγράφει αναλυτικά τα ενδιάμεσα στάδια από το αρχικό προς το αντιπαραγοντικό input, επισημαίνοντας σε κάθε βήμα ποια μεταβολή έγινε και πώς αυτή επηρέασε το evidence margin (τη διαφορά εμπιστοσύνης μεταξύ των πιθανών κλάσεων). Ξεκινώντας από μια αρχική είσοδο, ο αλγόριθμος δημιουργεί σταδιακά παραλλαγές, τροποποιώντας κάθε φορά ένα ή περισσότερα χαρακτηριστικά, με σκοπό να εντοπίσει τα σημεία στα οποία η πρόβλεψη του μοντέλου αλλάζει κατηγορία, δηλαδή το πέρασμα από τη μία πλευρά του decision boundary στην άλλη.

Σε πιο πρακτικό επίπεδο, ο αλγόριθμος λειτουργεί μεθοδικά. Αρχικά, υπολογίζεται το evidence margin για το αρχικό input (π.χ. μια πρόταση με έντονη αρνητική πρόβλεψη). Στη συνέχεια, τα χαρακτηριστικά της εισόδου μεταβάλλονται διαδοχικά, με κάθε αλλαγή να επιλέγεται με σκοπό να έχει τη μικρότερη δυνατή επίδραση στο evidence margin. Για παράδειγμα, αν η λέξη "occasional" αντικατασταθεί με "rare", το evidence margin μειώνεται σε απόλυτη τιμή, πλησιάζοντας το decision boundary. Έπειτα, ακολουθούνται επαναληπτικά βήματα, με στόχο τη χαρτογράφηση της πιο σύντομης και ήπιας διαδρομής προς το αντιπαραγοντικό input, δηλαδή εκείνο που προκαλεί αλλαγή κατηγορίας στην πρόβλεψη του μοντέλου. Η τελική επιλογή του counterfactual input γίνεται βάσει του ελάχιστου πλήθους μεταβολών και, σε περίπτωση ισοβαθμίας της μικρότερης ευκλείδειας απόστασης στον λανθάνοντα χώρο, εξασφαλίζει μια ομαλή και τεκμηριωμένη αλλαγή απόφασης.

3.1.2.2 Model-Agnostic Counterfactual

Ο κεντρικός στόχος της Εξηγήσιμης Τεχνητής Νοημοσύνης είναι η παραγωγή εξηγήσεων που να είναι κατανοητές από τον άνθρωπο, απαντώντας στα ερωτήματα «γιατί» και «πώς» το μοντέλο κατέληξε σε μια συγκεκριμένη πρόβλεψη. Για να είναι μια εξήγηση αποτελεσματική, είναι απαραίτητο να τηρεί τρεις θεμελιώδεις απαιτήσεις. Χρειάζεται να εξηγεί γιατί συνέβη κάτι και όχι κάτι άλλο, να εστιάζει σε βασικές αιτίες και όχι σε όλες, και να παρέχει διαδραστικότητα, επιτρέποντας στον χρήστη να μαθαίνει μέσα από διάλογο με το σύστημα. Επίσης, οι άνθρωποι έχουν φυσική τάση για αιτιακή σκέψη, κατασκευάζοντας μοντέλα αιτίας-αποτελέσματος ακόμη και με περιορισμένα δεδομένα. Έτσι, το ζητούμενο για τα συστήματα ΧΑΙ είναι να προσφέρουν εξηγήσεις που είναι κατανοητές και αιτιακές για τον τελικό χρήστη.

Η μετάβαση από τη συσχέτιση στην αιτιότητα αποτελεί θεμελιώδες βήμα για να επιτευχθεί πραγματική επεξηγησιμότητα στα συστήματα τεχνητής νοημοσύνης. Ενώ οι σύγχρονες τεχνικές ΧΑΙ συνήθως βασίζονται σε τοπικές συσχετίσεις για να αιτιολογήσουν την πρόβλεψη ενός μαύρου κουτιού, αυτό δεν εγγυάται πάντοτε την ύπαρξη αιτιακής σχέσης. Η ασάφεια αυτή μπορεί να οδηγήσει σε ψευδείς ή παραπλανητικές εξηγήσεις, κυρίως όταν το μοντέλο εστιάζει σε μη σχετικά μοτίβα που τυχαία συνδέονται με το επιθυμητό αποτέλεσμα (όπως η συστηματική παρουσία ενός μεταλλικού αντικειμένου σε ακτινογραφίες συγκεκριμένης πάθησης). Συνεπώς, μια εξήγηση που βασίζεται αποκλειστικά σε συσχετίσεις δεν προάγει τη «causability», δηλαδή την ικανότητα του συστήματος να παρέχει αιτιακά τεκμηριωμένες εξηγήσεις που οδηγούν σε πραγματική κατανόηση.

Οι counterfactual εξηγήσεις αποτελούν μια καινοτόμο κατηγορία, προσφέροντας όχι μόνο ανάλυση του υπάρχοντος αποτελέσματος αλλά και καθοδήγηση για μελλοντικές ενέργειες. Παρότι η υλοποίησή τους είναι εφικτή τόσο με model-specific όσο και με model-agnostic προσεγγίσεις, δίνεται μεγαλύτερη έμφαση στις ανεξάρτητες από το μοντέλο τεχνικές, ώστε να διασφαλιστεί η ανεξαρτησία από τη δομή και την αρχιτεκτονική του εκάστοτε αλγοριθμικού συστήματος, επιτρέποντας την ευρεία και ευέλικτη εφαρμογή του σε διαφορετικά περιβάλλοντα.

Σε αυτή την προσέγγιση, το σύστημα δημιουργεί εναλλακτικές εκδοχές του ίδιου παραδείγματος με ελάχιστες δυνατές μεταβολές στα χαρακτηριστικά του, ώστε το αποτέλεσμα της πρόβλεψης να αλλάζει. Με αυτόν τον τρόπο, οι counterfactuals απαντούν στο ερώτημα: «Τι θα έπρεπε να αλλάξει για να επιτευχθεί το επιθυμητό αποτέλεσμα;» Ένα χαρακτηριστικό παράδειγμα είναι η αίτηση δανείου, όπου το σύστημα ενημερώνει τον χρήστη: «Αν το εισόδημά σας ήταν άνω των 15.000€, το δάνειο θα είχε εγκριθεί». Αυτό προσφέρει πρακτική και έγκυρη πληροφόρηση, καθιστώντας τις εξηγήσεις ουσιαστικά χρήσιμες και εύκολα κατανοητές.

Επιπλέον, η ελάχιστη αλλαγή ως κριτήριο ερμηνευσιμότητας αποτελεί βασική αρχή των counterfactual εξηγήσεων, καθώς ορίζεται ως η μικρότερη δυνατή μεταβολή σε μια αρχική εγγραφή δεδομένων που οδηγεί σε διαφορετικό αποτέλεσμα. Πρακτικά,

αναζητείται το κοντινότερο εναλλακτικό παράδειγμα x' , ξεκινώντας από το αρχικό σημείο x και αλλάζοντας όσο το δυνατόν λιγότερα χαρακτηριστικά, ώστε η έξοδος του μοντέλου να μεταβληθεί. Η απόσταση $d(x, x')$ μετρά το βαθμό διαφοροποίησης του counterfactual σε σχέση με το πρωτότυπο, και το πιο βέλτιστο είναι εκείνο που απαιτεί τον ελάχιστο αριθμό αλλαγών (υψηλή αραιότητα), αλλάζει κατηγορία και παραμένει εύκολα ερμηνεύσιμο.

Για τον υπολογισμό αυτής της απόστασης, χρησιμοποιούνται κυρίως οι L_p -norms. Η L_0 -norm μετρά πόσα χαρακτηριστικά διαφέρουν μεταξύ των δύο παραδειγμάτων και οδηγεί σε αρκετά αραιές λύσεις, αν και είναι μη διαφορίσιμη και δύσκολη στη βελτιστοποίηση. Η L_1 -norm (Manhattan απόσταση) περιορίζει τη συνολική μεταβολή, προάγοντας επίσης την αραιότητα, αλλά παρουσιάζει γεωμετρικές δυσκολίες στη βελτιστοποίηση και η L_2 -norm (ευκλείδεια απόσταση) είναι υπολογιστικά αποδοτική και πλήρως διαφορίσιμη, αν και δεν οδηγεί απαραίτητα σε sparse λύσεις. Τέλος, η L_∞ -norm περιορίζει τη μέγιστη μεταβολή σε οποιοδήποτε χαρακτηριστικό, είναι σχεδόν παντού διαφορίσιμη και χρησιμεύει κυρίως στον έλεγχο των πιο ακραίων τιμών των αλλαγών.

Οι ιδιότητες για την παραγωγή ποιοτικών counterfactual εξηγήσεων αποτελούν βασικό κριτήριο αξιοπιστίας και χρησιμότητας των παραγόμενων αποτελεσμάτων. Η εγγύτητα (proximity) αναφέρεται στο πόσο κοντά βρίσκεται το counterfactual στο αρχικό παράδειγμα, κάτι που υπολογίζεται μέσω συναρτήσεων απόστασης όπως η ευκλείδεια απόσταση, το Nearest Neighbour Search ή το cosine similarity. Η λογικότητα (plausibility) εξασφαλίζει ότι τα counterfactuals δεν προτείνουν ακατάλληλες αλλαγές σε αμετάβλητα χαρακτηριστικά (όπως φύλο ή φυλή), αλλά εστιάζουν σε μεταβλητές που μπορούν ρεαλιστικά να τροποποιηθούν, όπως το εισόδημα. Επιπλέον, η αραιότητα (sparsity) επιδιώκει να μεταβληθούν όσο το δυνατόν λιγότερα χαρακτηριστικά, ώστε το counterfactual να είναι πιο εύκολα ερμηνεύσιμο από τον άνθρωπο.

Παράλληλα, η ποικιλομορφία (diversity) αφορά την παραγωγή πολλών διαφορετικών counterfactuals για το ίδιο αρχικό παράδειγμα, προσφέροντας πιο εμπλουτισμένες και κατανοητές ερμηνείες στον χρήστη. Τέλος, η εφικτότητα στην πράξη (feasibility) διασφαλίζει ότι οι αλλαγές που προτείνονται από τα counterfactuals είναι ρεαλιστικές και εφαρμόσιμες στον πραγματικό κόσμο, καθώς μαθηματικά βέλτιστα counterfactuals μπορεί να εντοπίζονται σε οριακές ή ασαφείς περιοχές του χώρου των δεδομένων, καθιστώντας τες λιγότερο χρήσιμες ή αβέβαιες στην πράξη.

Όσον αφορά την υλοποίηση των counterfactual εξηγήσεων, αυτή προσαρμόζεται ανάλογα με τον τύπο των δεδομένων. Για δομημένα δεδομένα (όπως πίνακες και χρονοσειρές), η μέθοδος MACE (model-agnostic counterfactual explanations) παρέχει αποδοτικές και αξιόπιστες εναλλακτικές ακόμη και σε σύνθετα black-box μοντέλα με πολλά χαρακτηριστικά. Όσον αφορά τις εικόνες, η παραγωγή counterfactuals βασίζεται σε αλγορίθμους βελτιστοποίησης που εντοπίζουν τα ελάχιστα απαραίτητα pixels που πρέπει να αλλάξουν για να μεταβληθεί η πρόβλεψη του μοντέλου. Επιπλέον, στο πεδίο του κειμένου, εργαλεία όπως το Polyjuice αξιοποιούν προεκπαιδευμένα γλωσσικά

μοντέλα για να παράγουν ποικίλες εναλλακτικές διατυπώσεις, οι οποίες αξιολογούνται ως προς την αλλαγή της πρόβλεψης και τη συνάφειά τους με το αρχικό κείμενο, εξασφαλίζοντας έτσι την εγκυρότητα και την πληρότητα της εξήγησης.

3.1.2.2.1 Instance-Centric

Οι instance-centric προσεγγίσεις (Lewis, Sandra et al.) για την παραγωγή counterfactual εξηγήσεων δημιουργούν εναλλακτικά παραδείγματα εφαρμόζοντας τυχαίες μεταθέσεις χαρακτηριστικών και ελαχιστοποιώντας την καθορισμένη συνάρτηση απόστασης, ώστε να εντοπιστούν παραδείγματα που βρίσκονται όσο το δυνατόν πιο κοντά στο αρχικό. Παρόλο που η προσέγγιση αυτή είναι απλή, συχνά αδυνατεί να διασφαλίσει σημαντικές ιδιότητες όπως η λογικότητα, η εφικτότητα και η ποικιλομορφία των παραγόμενων counterfactuals. Για τον λόγο αυτό, οι πιο σύγχρονοι αλγόριθμοι ενσωματώνουν σχετικούς όρους στις loss functions τους, ώστε να διασφαλίζεται η ποιότητα των εξηγήσεων. Ενδεικτικά, το FACE αξιοποιεί τον αλγόριθμο του Dijkstra για να εντοπίσει τη συντομότερη και πιο ρεαλιστική διαδρομή μεταξύ των σημείων εκπαίδευσης και του προς ανάλυση παραδείγματος, επιτρέποντας την επιβολή περιορισμών εφικτότητας και εμπιστοσύνης στον ταξινομητή.

Παράλληλα, η χρήση της L2-norm και των κατάλληλων σταθμίσεων διασφαλίζει ότι οι εξηγήσεις θα παραμένουν πρακτικά εφαρμόσιμες και θα αποφεύγονται παράδοξες ή μη ρεαλιστικές προτάσεις. Το DiCE (Diverse Counterfactual Explanations, Mothilal et al.) αποτελεί εξελιγμένη εκδοχή αυτής της λογικής, ενσωματώνοντας έννοιες όπως η ποικιλομορφία, η εγγύτητα και η αραιότητα. Ταυτόχρονα, παράγει πολλαπλές και ερμηνεύσιμες εναλλακτικές για το ίδιο αρχικό παράδειγμα, παρέχοντας στο χρήστη δυνατότητα επιλογής, ενώ αξιοποιεί determinant point process για να διασφαλιστεί η ποικιλομορφία. Επιπλέον, η loss function του DiCE συνδυάζει εγγύτητα, αραιότητα και ποικιλομορφία, με την L1-norm να είναι κανονικοποιημένη ως προς τη διάμεση απόκλιση κάθε χαρακτηριστικού, και η βελτιστοποίηση υλοποιείται με gradient descent, παρέχοντας ερμηνευσιμότητα και επιλογές προσαρμοσμένες στις ανάγκες του τελικού χρήστη.

3.1.2.2.1.1 Polyjuice

Το Polyjuice ταξινομείται ως instance-centric εργαλείο counterfactual εξηγήσεων και χρησιμοποιείται για τη δημιουργία εναλλακτικών παραδειγμάτων κειμένου με στόχο τη διερεύνηση σεναρίων «τι θα γινόταν αν». Ξεκινώντας από μια αρχική πρόταση (π.χ. «It is great for kids.»), το Polyjuice παράγει υποψήφια counterfactuals εφαρμόζοντας ελεγχόμενες στρατηγικές τροποποίησης, όπως η διαγραφή φράσεων, η αρνητικοποίηση (π.χ. «It is not great for kids.»), η λεκτική αντικατάσταση (π.χ. «It is great for adults.»), η επαναδιατύπωση, η εισαγωγή και η αναδιάρθρωση φράσεων, καλύπτοντας έτσι ένα μεγάλο εύρος πιθανών αλλαγών. Επιπλέον, για κάθε παραγόμενο παράδειγμα, αξιολογεί εάν η τροποποίηση προκαλεί ουσιαστική διαφοροποίηση στην πρόβλεψη του μοντέλου (π.χ. αλλαγή ετικέτας) και αν το νέο κείμενο παραμένει συντακτικά και νοηματικά κοντά στο αρχικό. Η αυτοματοποίηση αυτής της διαδικασίας, επομένως, μειώνει δραστικά τον χειροκίνητο φόρτο συγκριτικά με τις παραδοσιακές μεθόδους και βοηθά στον εντοπισμό «τυφλών σημείων» ή αδυναμιών των μοντέλων, όπως για παράδειγμα όταν η αλλαγή σημαντικών λέξεων δεν επηρεάζει την πρόβλεψη.

3.1.2.2.2 Constraint-Centric

Οι μέθοδοι constraint-centric παρουσιάζουν την αναζήτηση counterfactual εξηγήσεων ως πρόβλημα ικανοποίησης περιορισμών (SMT), συνδυάζοντας κριτήρια απόστασης και περιορισμούς σε μία λογική φόρμουλα που επιλύεται μέσα από SMT solvers, επιτρέποντας την εύρεση counterfactuals εντός προκαθορισμένων ορίων με υποστήριξη οποιασδήποτε Lp-norm και πλήθους περιορισμών. Το MACE συγκεκριμένα (Model-Agnostic Counterfactual Explanations for Consequential Decisions) ξεχωρίζει για την ικανότητά του να παράγει counterfactuals σε μικρότερες αποστάσεις, προσφέροντας υψηλότερη κάλυψη και λειτουργικότητα.

Αντίστοιχα, η προσέγγιση των Coherent Counterfactuals του Russell εστιάζει στην παραγωγή συνεκτικών και ποικίλων counterfactuals μέσω της μεθόδου mixed polytope, η οποία είναι κατάλληλη για δεδομένα με συνεχείς και διακριτές μεταβλητές. Πιο συγκεκριμένα, ο Russell ορίζει νέα κριτήρια συνεκτικότητας ενσωματωμένα σε ένα καινοτόμο πλαίσιο περιορισμών, διασφαλίζοντας ότι οι λύσεις παραμένουν εντός του αρχικού χώρου του προβλήματος. Η διαδικασία αυτή ξεκινάει με την εύρεση της ελάχιστης αλλαγής που απαιτείται για την αναστροφή της πρόβλεψης μέσω L1-norm, και συνεχίζει με την κατασκευή του mixed polytope για την επίτευξη ποικιλομορφίας. Τελικός στόχος αποτελεί η επιλογή των πλέον συνεκτικών λύσεων μέσω integer programming, προσφέροντας περισσότερο αξιόπιστα και εύληπτα counterfactuals.

3.1.2.2.3 Genetic-Centric

Όσον αφορά τις γενετικές προσεγγίσεις, αυτές αξιοποιούν αρχές από τους γενετικούς αλγόριθμους, όπως τη μετάλλαξη και τον συνδυασμό χαρακτηριστικών, με στόχο τη δημιουργία ενός εμπλουτισμένου συνόλου εναλλακτικών λύσεων που διακρίνονται για την ποικιλομορφία και την εφικτότητά τους. Από τις πλέον πιο σύγχρονες και ολοκληρωμένες μεθόδους είναι η MOCE (Multi-Objective Counterfactual Explanations), (Dandl et al., 2020), η οποία διατυπώνει το πρόβλημα ως πολυκριτηριακή βελτιστοποίηση και βασίζεται στον αλγόριθμο NSGA-II, διατηρώντας μια σημαντική ισορροπία μεταξύ τεσσάρων κρίσιμων στόχων: εγγύτητας προς την επιθυμητή πρόβλεψη, ομοιότητας με το αρχικό παράδειγμα, αραιότητας των μεταβολών και πιθανότητας εμφάνισης στη δεδομένη κατανομή. Έτσι, ο MOCE προσφέρει στον χρήστη ρεαλιστικές και ερμηνεύσιμες εξηγήσεις, οι οποίες προσαρμόζονται ταυτόχρονα σε πολλαπλά κριτήρια. Η υπεροχή αυτή της MOCE έναντι διάφορων προσεγγίσεων, όπως οι LORE και οι CERTIFAI, έγκειται στην ικανότητά της να παράγει πιο ποικίλες και ρεαλιστικές εξηγήσεις. Το LORE, από την άλλη, περιορίζεται κυρίως σε decision trees με μικρότερη ποικιλομορφία, ενώ το CERTIFAI εστιάζει στη δικαιοσύνη, χωρίς να διαθέτει το ίδιο επίπεδο βελτιστοποίησης.

3.1.2.2.4 Regression-Centric

Οι προσεγγίσεις που βασίζονται στη γραμμική παλινδρόμηση και τη θεωρία παιγνίων, όπως το SHAP, συχνά λειτουργούν στο πλαίσιο του LIME, χρησιμοποιώντας γραμμικά μοντέλα για να προσεγγίσουν τη συνεισφορά κάθε χαρακτηριστικού μέσω ανακατατάξεων στις εισόδους. Παρά τη διαφάνεια που προσφέρουν, τα counterfactuals που παράγονται με αυτές τις τεχνικές συχνά υστερούν σε λογικότητα και ποικιλομορφία, καθώς τείνουν να προσφέρουν μια πιο περιορισμένη και στατική ερμηνευσιμότητα σε σύγκριση με άλλες σύγχρονες μεθόδους.

Το LIME-C (Local Interpretable Model-Agnostic Explanations-Counterfactual) των Ramon et al. συνδυάζει τις προσθετικές αποδόσεις χαρακτηριστικών του LIME με την παραγωγή counterfactual εξηγήσεων, αξιοποιώντας τις ακριβείς κατατάξεις σημασίας των χαρακτηριστικών για να υπολογίζει γρήγορα και αποδοτικά τα προς εξέταση counterfactuals μέσω του αλγορίθμου SEDC, με αποτέλεσμα να εφαρμόζει μια γραμμική προσέγγιση του αρχικού ταξινομητή. Η μέθοδος αυτή αποδεικνύεται σταθερή και αποδοτική σε ποικιλία δεδομένων και μοντέλων, ακόμη και όταν απαιτείται η αφαίρεση πολλών χαρακτηριστικών για την αλλαγή της προβλεπόμενης κλάσης.

3.1.2.2.5 Game Theory-Centric

Οι προσεγγίσεις που βασίζονται στη θεωρία παιγνίων, όπως το SHAP, χρησιμοποιούν τις τιμές Shapley για να προσδιορίσουν τη σημασία κάθε χαρακτηριστικού στην τελική πρόβλεψη σε τοπικό επίπεδο. Παρ' όλα αυτά, τα counterfactuals που παράγονται με αυτές τις τεχνικές συχνά δυσκολεύονται να εξασφαλίσουν τη λογικότητα και την ποικιλομορφία που απαιτούνται για να προκύψουν πλήρως αξιόπιστες εξηγήσεις. Σε αυτό το πλαίσιο, έχουν αναπτυχθεί δύο ενδεικτικές παραλλαγές: το SHAP-C και το SHAP-CC. Το SHAP-C συνδυάζει το Kernel SHAP με τον αλγόριθμο SEDC για τη δημιουργία counterfactual εξηγήσεων, ξεκινώντας με τον υπολογισμό των τιμών Shapley κάθε χαρακτηριστικού, την επιλογή των σημαντικότερων ως Evidence Counterfactual, και τη στοχευμένη μεταβολή τους έως ότου αντιστραφεί η πρόβλεψη του μοντέλου. Από την άλλη, το SHAP-CC εφαρμόζει τη μεθοδολογία P-contrastive, παράγοντας αντιθετικές εξηγήσεις που αποκαλύπτουν θετικές και αρνητικές συμβολές χαρακτηριστικών με σαφήνεια στη φυσική γλώσσα.

3.1.2.2.6 Case-Based Reasoning

Επιπλέον, οι μέθοδοι case-based reasoning (CBR) βασίζονται στην αποθήκευση παραδειγμάτων ποιοτικών counterfactuals, δηλαδή αραιών, λογικών, ποικίλων και εφικτών, τα οποία αξιοποιούνται ως μνήμη για μελλοντικές εξηγήσεις. Στην προσέγγιση CBR for Good Counterfactuals των Keane και Smyth, η επιλογή των παραδειγμάτων καθορίζεται από τα κριτήρια explanatory coverage και counterfactual potential, ώστε να διασφαλίζεται υψηλή ποιότητα, λογικότητα και ποικιλομορφία στις παραγόμενες εξηγήσεις. Κάθε explanation case (XC) αντιστοιχεί σε ένα ζεύγος πρωτότυπου και ποιοτικού counterfactual. Για τη δημιουργία νέου counterfactual, επιλέγεται το XC που προσομοιάζει περισσότερο στο υπό εξέταση παράδειγμα, μεταφέρονται τα κοινά χαρακτηριστικά και προστίθενται εκλεκτά διαφοροποιημένα στοιχεία για την ενίσχυση της ποικιλομορφίας. Στην περίπτωση που η πρόβλεψη αλλάξει κατηγορία, το παράδειγμα θεωρείται έγκυρο, αλλιώς πραγματοποιούνται περαιτέρω προσαρμογές ώσπου να επιτευχθεί η επιθυμητή μεταβολή.

3.1.2.2.6.1 Prototype Models

Τα prototype models ανήκουν στην κατηγορία της συλλογιστικής βάσει περιπτώσεων. Σε αυτήν την προσέγγιση, το νευρωνικό δίκτυο, λαμβάνοντας ως είσοδο ένα νέο παράδειγμα (π.χ. κείμενο), υπολογίζει τη μέγιστη ομοιότητα του input με ένα σύνολο αποθηκευμένων πρωτοτύπων (prototypes), δηλαδή παραδειγμάτων-εκπροσώπων κάθε κλάσης που έχουν επιλεγεί κατά την εκπαίδευση. Το πιο κοντινό prototype (π.χ. η φράση

"Routine and rather silly.") παρουσιάζεται στον χρήστη μαζί με το σκορ ομοιότητας (π.χ. 9.96/10), προσφέροντας ένα άμεσα ερμηνεύσιμο παράδειγμα που συνέβαλε στην τελική απόφαση του μοντέλου. Αυτή η στρατηγική προάγει τη διαφάνεια στη διαδικασία ταξινόμησης, καθώς ο χρήστης ενημερώνεται όχι μόνο για το τελικό αποτέλεσμα, αλλά και για το σκεπτικό της απόφασης: «Το input σου μοιάζει περισσότερο με αυτό το ήδη γνωστό παράδειγμα». Επιπλέον, το prototype model μπορεί να αναδείξει ποια χαρακτηριστικά (όπως λέξεις ή τιμές πεδίων) ήταν σημαντικά για τη σύγκριση, αν και στην πράξη, σε ορισμένες περιπτώσεις, αυτά δεν αναδεικνύονται πάντα.

Για τα κείμενα, η σημασία ενός χαρακτηριστικού υπολογίζεται αφαιρώντας μια λέξη και αντικαθιστώντας το embedding της με μηδενικό διάνυσμα, σαν να απουσιάζει εντελώς από την είσοδο και υπολογίζεται η αλλαγή στο σκορ εξόδου του μοντέλου. Στα δομημένα δεδομένα (πίνακες), αντί να μηδενιστούν οι τιμές, χρησιμοποιείται η τεχνική του imputation, όπου αντικαθιστάται το χαρακτηριστικό με πιθανές τιμές μέσω πολυωνυμικής λογιστικής παλινδρόμησης και υπολογίζεται η αναμενόμενη τιμή της εξόδου. Η έρευνα των Hase & Bansal (2020) δείχνει ότι οι prototype εξηγήσεις βελτιώνουν σημαντικά την ικανότητα του χρήστη να προβλέψει την αντίδραση του μοντέλου σε μικρές μεταβολές του input (counterfactual simulation), αυξάνοντας έτσι την κατανόηση και την εμπιστοσύνη στο μοντέλο. Ωστόσο, η αποτελεσματικότητα αυτής της μεθόδου περιορίζεται όταν το prototype δεν συνοδεύεται από σημαντικά χαρακτηριστικά, ή όταν το ίδιο το prototype δεν έχει σαφή νοηματική σχέση με το input. Συνεπώς, η επιτυχία των prototype models εξαρτάται από τη σαφή σύνδεση input–prototype και την ανάδειξη των πιο κρίσιμων χαρακτηριστικών κατά τη διαδικασία σύγκρισης.

3.1.2.2.7 Probabilistic-Centric

Οι πιθανοκρατικές μέθοδοι βασίζονται σε τυχαίες διαδικασίες, δειγματοληψία ή γραφικά μοντέλα και μπορούν να ενσωματώσουν το αιτιατό πλαίσιο του Pearl, προσφέροντας πιο ισχυρές και κατανοητές εξηγήσεις. Στην ουσία, εντοπίζουν το πλησιέστερο counterfactual μέσω πιθανοκρατικών μοντέλων, ενώ οι σύγχρονες προσεγγίσεις, όπως το Recourse (Karimi et al., 2019), παράγουν αιτιακά counterfactuals βασισμένα σε δομημένα αιτιακά μοντέλα (SCMs). Η εκμάθηση αυτών των αιτιακών σχέσεων από παρατηρούμενα δεδομένα παραμένει σημαντική πρόκληση και συχνά απαιτεί υποθέσεις για το μοντέλο, κάτι που μπορεί να επηρεάσει την εγκυρότητα των εξηγήσεων.

Επιπλέον, η προσέγγιση Recourse δεν περιορίζεται στον εντοπισμό του πλησιέστερου counterfactual, αλλά παρέχει ένα σύνολο δράσεων που επιτρέπουν στον χρήστη να επιτύχει ένα πιο ευνοϊκό αποτέλεσμα, λαμβάνοντας υπόψη το εξατομικευμένο κόστος και τη χρησιμότητα. Οι Karimi et al. (2019) εισάγουν δύο πιθανοκρατικές μεθόδους για την πιο εύκολη υλοποίηση ενός πλήρους SCM. Η πρώτη προσθέτει ένα Gaussian θόρυβο και εφαρμόζει ένα Bayesian model averaging για την εκτίμηση της κατανομής των counterfactuals, ενώ η δεύτερη παρακάμπτει τις δομικές αιτιακές εξισώσεις και υπολογίζει το μέσο αποτέλεσμα των δράσεων recourse. Τα πειράματα αυτά καταδεικνύουν ότι το Recourse προσφέρει ρεαλιστικές και αξιόπιστες συστάσεις ακόμη και με μερική γνώση του SCM, αποτελώντας μια ολοκληρωμένη προσέγγιση όπου η αιτία και η δράση συνδυάζονται λειτουργικά.

3.1.2.2.8 Βασικά Συστατικά ενός Αιτιατού Συστήματος

Οι θεμελιώδεις ιδιότητες του αιτιατού συστήματος ξεκινούν με τη θεμελίωση της έννοιας της αιτιότητας. Η παρουσίαση αιτιακών σχέσεων μεταξύ μεταβλητών έχει τη δυνατότητα να ενισχύσει την ανθρώπινη κατανόηση, ωστόσο το αποτέλεσμα ποικίλλει ανάλογα με το γνωστικό υπόβαθρο του χρήστη. Σύμφωνα με διάφορες μελέτες, σε χρήστες με ήδη ανεπτυγμένη σχετική γνώση η αιτιότητα δεν βελτιώνει ουσιαστικά τη λήψη αποφάσεων, ενώ σε αυτούς που είναι λιγότερο έμπειροι προσφέρει σημαντική ενίσχυση στην ικανότητα κατανόησης και δράσης. Επιπλέον, ένα αποτελεσματικό causability system οφείλει να παρέχει counterfactual εξηγήσεις, αφού η αντεπαγωγική σκέψη αποτελεί θεμέλιο της ανθρώπινης μάθησης και προσαρμοστικής συμπεριφοράς. Τα counterfactuals, επομένως, διαμορφώνουν πραγματικές νοητικές αναπαραστάσεις αιτίας-αποτελέσματος, ενισχύοντας τη σαφήνεια και την ποικιλομορφία των παραγόμενων παραδειγμάτων.

Ένα τρίτο βασικό στοιχείο είναι ο ανθρωποκεντρικός σχεδιασμός (human-centric design) και η διαδραστική προσαρμογή. Οι εξηγήσεις πρέπει να ανταποκρίνονται στις ανάγκες, τις προτιμήσεις και το γνωστικό επίπεδο κάθε χρήστη, ενσωματώνοντας μηχανισμούς αιτιακής συμπερασματολογίας και σημασιολογικού σχολιασμού. Η υιοθέτηση της προσέγγισης human-in-the-loop, με χρήση contextual knowledge και εξειδικευμένης πληροφορίας, ενισχύει ουσιαστικά την εμπιστοσύνη και την κατανόηση του χρήστη για το σύστημα. Ιδιαίτερη σημασία έχει η δυνατότητα του χρήστη να θέτει ερωτήματα στο σύστημα ("αν ο ασθενής έχει πυρετό, πώς αλλάζει η εξήγηση;"), προάγοντας κατά συνέπεια τη διαφάνεια και την ενεργή αλληλεπίδραση. Παράλληλα, διάφορα εργαλεία όπως το What-IF Tool, το ViCE και το DECE παρέχουν διαδραστικές οπτικές διεπαφές για εξερεύνηση εναλλακτικών σεναρίων («τι θα γινόταν αν...»), διευκολύνοντας την εμβάθυνση στη λογική του μοντέλου. Τέτοιες πλατφόρμες αναδεικνύουν τον κρίσιμο ρόλο της οπτικοποίησης και της αλληλεπίδρασης ως βασικών συνιστωσών της σύγχρονης ερμηνευσιμότητας, ενώ συνολικά η διαδικασία παραγωγής εξηγήσεων χρειάζεται να υπερβαίνει την απλή μαθηματική βελτιστοποίηση και να δίνει προτεραιότητα στην ανθρώπινη κατανόηση, την αλληλεπίδραση και την προσαρμοστικότητα στις ανάγκες του τελικού χρήστη.

3.1.2.3 Model-Specific Τεχνικές

Οι model-specific τεχνικές αποτελούν μεθόδους εξήγησης που βασίζονται στην εις βάθος γνώση της εσωτερικής λειτουργίας του ίδιου του μοντέλου, λαμβάνοντας υπόψη χαρακτηριστικά όπως η γραμμικότητα, η δυνατότητα υπολογισμού παραγώγων ή οι διαδρομές απόφασης. Αναλυτικότερα, εστιάζουν στη δομή και στα εσωτερικά του μοντέλου, όπως τα βάρη, τα gradients και τα decision paths, προκειμένου να αναλύσουν με λεπτομέρεια τον τρόπο λήψης αποφάσεων. Το βασικό τους πλεονέκτημα είναι η δυνατότητα για εις βάθος ανάλυση των αποφάσεων, όπως η οπτικοποίηση των ενεργοποιήσεων σε συνελκτικά νευρωνικά δίκτυα (CNN) και η αναλυτική παρακολούθηση των διαδρομών απόφασης σε δέντρα.

Ωστόσο, το κύριο μειονέκτημα αυτών των μεθόδων είναι η περιορισμένη γενικότητά τους, καθώς απαιτούν συμβατότητα με συγκεκριμένες αρχιτεκτονικές και πλατφόρμες.

Ενδεικτικά παραδείγματα αποτελούν τα Integrated Gradients (IG) και Grad-CAM, που βασίζονται στον υπολογισμό παραγώγων και εφαρμόζονται κυρίως σε νευρωνικά δίκτυα υλοποιημένα σε PyTorch ή TensorFlow, ενώ τεχνικές όπως η Contrastive Explanation Method (CEM) και το Feature Visualization απαιτούν διαφορίσιμα μοντέλα για να παρέχουν ουσιαστικές θετικές ή αρνητικές εξηγήσεις, αλλά ταυτόχρονα περιορίζονται από την αυξημένη υπολογιστική πολυπλοκότητα.

3.1.2.3.1 Grad-CAM

Το Grad-CAM (Gradient-weighted Class Activation Mapping) αποτελεί μία από τις πλέον πιο διαδεδομένες και αποτελεσματικές μεθόδους ερμηνείας για συνελκτικά νευρωνικά δίκτυα (CNN), δημιουργώντας heatmaps που αναδεικνύουν ποιες περιοχές μιας εικόνας συνέβαλαν περισσότερο στην τελική πρόβλεψη του μοντέλου. Μέσω αυτής της διαδικασίας, ο χρήστης μπορεί να κατανοήσει σε ποια οπτικά στοιχεία επικεντρώθηκε το δίκτυο και πώς αυτά επηρέασαν την απόφαση.

Η λειτουργία του Grad-CAM ξεκινάει με το πέρασμα της εικόνας από τα συνελκτικά layers, όπου κάθε layer εξάγει διαφορετικά πρότυπα και χαρακτηριστικά. Στο τελευταίο layer, κάθε feature map σταθμίζεται ανάλογα με τη σημασία του για μια συγκεκριμένη κλάση, χρησιμοποιώντας βαρύτητες που προκύπτουν από τις παραγώγους της εξόδου ως προς κάθε feature map. Στη συνέχεια, τα σταθμισμένα feature maps συνδυάζονται για να παραχθεί το τελικό heat map, αποκαλύπτοντας ποιες περιοχές της αρχικής εικόνας επηρέασαν περισσότερο την πρόβλεψη και ενισχύοντας έτσι τη διαφάνεια του μοντέλου. Το Grad-CAM διακρίνεται για την ταχύτητα, την αξιοπιστία και την ευελιξία του, καθώς μπορεί να εφαρμοστεί σε κάθε CNN χωρίς τροποποίηση της αρχιτεκτονικής, ωστόσο επειδή δεν είναι model-agnostic, παρέχει σχετικά αδρό εντοπισμό, τονίζοντας περιοχές αλλά όχι συγκεκριμένες λεπτομέρειες εντός αυτών.

3.1.2.3.2 CEM

Η CEM (Contrastive Explanation Method) αποτελεί μια καινοτόμο προσέγγιση στην ερμηνεία των μοντέλων, καθώς υπερβαίνει τις κλασικές τεχνικές που εστιάζουν αποκλειστικά στα θετικά χαρακτηριστικά. Η CEM εξηγεί μια ταξινόμηση χρησιμοποιώντας μια contrastive λογική: «Αυτό το δείγμα ανήκει στην κλάση Y επειδή τα χαρακτηριστικά A , B , Γ είναι παρόντα και επειδή τα χαρακτηριστικά Δ και E απουσιάζουν». Εντοπίζει δηλαδή δύο διακριτές κατηγορίες χαρακτηριστικών: τα Pertinent Positives (PPs), δηλαδή τα ελάχιστα και απαραίτητα χαρακτηριστικά που πρέπει να υπάρχουν για να δικαιολογηθεί η συγκεκριμένη πρόβλεψη, και τα Pertinent Negatives (PNs), τα οποία είναι τα κρίσιμα χαρακτηριστικά που πρέπει να λείπουν ώστε η πρόβλεψη να μην αλλάξει προς μια γειτονική κλάση.

Αυτή η αντιθετική προσέγγιση αντανάκλα τον ανθρώπινο τρόπο σκέψης, όπου τόσο η παρουσία όσο και η απουσία συγκεκριμένων στοιχείων διαμορφώνει την τελική απόφαση. Η CEM έχει εφαρμοστεί ενδεικτικά σε δεδομένα fMRI εγκεφάλου, όπου χρησιμοποιήθηκε για να εξηγήσει τη διάκριση μεταξύ νευροτυπικών ατόμων και ατόμων που βρίσκονται στο φάσμα του αυτισμού, αναλύοντας πίνακες συνδεσιμότητας μεταξύ εγκεφαλικών

δικτύων (όπως το οπτικό VIS και το default mode network DMN). Μέσω αυτής της μεθόδου, οι βασικές συνδέσεις που απαιτούνται για τη διατήρηση της διάγνωσης αναγνωρίστηκαν ως PPs, ενώ οι συνδέσεις που πρέπει να απουσιάζουν για να μην αλλάξει η πρόβλεψη εντοπίστηκαν ως PNs. Η συγκεκριμένη αξιολόγηση έδειξε ότι το υποσύνολο των PPs διατηρεί πάντα την αρχική ταξινόμηση, ενώ η προσθήκη των PNs στο input οδηγεί με βεβαιότητα σε αλλαγή κλάσης.

3.1.2.3 Σύγκριση Model-Agnostic και Model-Specific

Παρά την κοινή αντίληψη ότι οι model-specific μέθοδοι, λόγω της άμεσης πρόσβασης στην εσωτερική αρχιτεκτονική του μοντέλου, θα υπερείχαν σε αξιοπιστία και βάθος ανάλυσης, αρκετά ερευνητικά ευρήματα (Sandu & Trăușan-Matu, RoCHI 2022) αναφέρουν ότι, σε μετρικές όπως η faithfulness (δηλαδή ο βαθμός στον οποίο η εξήγηση αντικατοπτρίζει πραγματικά τη λειτουργία του μοντέλου) και η Shannon entropy (που υπολογίζει την καθαρότητα και την αναγνωσιμότητα των εξηγήσεων, με χαμηλότερες τιμές να υποδηλώνουν πιο συνοπτικές και σαφείς εξηγήσεις), οι model-agnostic μέθοδοι παρέχουν συχνά πιο αξιόπιστες εξηγήσεις, ειδικά σε πολύπλοκα δεδομένα όπως είναι το κείμενο.

Η επιλογή μεταξύ model-agnostic και model-specific τεχνικών XAI εξαρτάται σε μεγάλο βαθμό από την εκάστοτε χρήση. Για την επίτευξη διαφάνειας, συγκρισιμότητας και ευελιξίας σε διαφορετικούς αλγόριθμους, οι model-agnostic μέθοδοι είναι συνήθως προτιμότερες, ενώ για την εις βάθος κατανόηση του τρόπου λειτουργίας των μοντέλων, ιδίως στα βαθιά νευρωνικά δίκτυα, οι model-specific προσεγγίσεις προσφέρουν μια πληρέστερη ανάλυση.

3.2 Ενοποιημένη Πλατφόρμα Εξηγήσεων: Υλοποίηση των Μεθοδολογιών

3.2.1 Omni XAI

Η ενότητα αυτή εστιάζει στην πρακτική υλοποίηση μεθοδολογιών ερμηνευσιμότητας μέσω της ενοποιημένης πλατφόρμας Omni XAI. Αν και υπάρχουν πολυάριθμες διαθέσιμες μέθοδοι, η εφαρμογή και η ερμηνεία τους συχνά παραμένουν δύσκολες στην πράξη. Η Omni XAI, μια ανοιχτού κώδικα βιβλιοθήκη Python, καλύπτει αυτό το κενό, προσφέροντας μια ολοκληρωμένη πλατφόρμα που επιτρέπει τη δημιουργία και την οπτικοποίηση εξηγήσεων σε όλα τα στάδια της μηχανικής μάθησης. Επιπλέον, ενσωματώνει διαφορετικές τεχνικές XAI σε ένα ενιαίο λειτουργικό περιβάλλον και υποστηρίζει ανάλυση δεδομένων σε μορφή πινάκων, εικόνων, κειμένου και χρονοσειρών, παρέχοντας συμβατότητα με scikit-learn, PyTorch και TensorFlow.

Μέσω μιας φιλικής και επεκτάσιμης διεπαφής, ο χρήστης μπορεί να εφαρμόσει, να συγκρίνει και να αξιολογήσει πληθώρα εργαλείων ερμηνευσιμότητας διαφανών, model-agnostic και model-specific προσεγγίσεων, συμπεριλαμβανομένων γνωστών τεχνικών όπως LIME, SHAP, Grad-CAM και PDP, με ελάχιστο κώδικα. Παράλληλα, αυτή η

πλατφόρμα προσφέρει διαδραστικό γραφικό πίνακα ελέγχου για ανάλυση και οπτικοποίηση, διευκολύνοντας τη σύγκριση και την κατανόηση των διαφορετικών εξηγήσεων. Η ροή εργασίας παραμένει απλή, ο χρήστης ορίζει το μοντέλο, επιλέγει μεθόδους επεξήγησης και το σύστημα παράγει εξηγήσεις με δυνατότητα άμεσης οπτικοποίησης. Συνολικά, το Omni XAI αποτελεί το πιο πλήρες και λειτουργικά πλούσιο οικοσύστημα εργαλείων XAI, καθιστώντας την εξηγήσιμη τεχνητή νοημοσύνη πιο προσιτή και αποτελεσματική από ποτέ.

3.2.2 Αρχιτεκτονική

Η αρχιτεκτονική της βιβλιοθήκης Omni XAI έχει σχεδιαστεί με γνώμονα τη φιλικότητα προς τον χρήστη (λίγος κώδικας για πλούσια αποτελέσματα), την επεκτασιμότητα (δυνατότητα προσθήκης νέων μεθόδων χωρίς αλλαγές στον πυρήνα) και τη συγκρισιμότητα (εύκολη αντιπαραβολή μεταξύ διαφορετικών εξηγήσεων). Η συγκεκριμένη υποδομή οργανώνεται σε τετραεπίπεδη αρχιτεκτονική με πέντε διακριτά υποσυστήματα:

- Input Layer (omnixai.data): όλοι οι τύποι δεδομένων (tabular, image, text, timeseries) τυποποιούνται σε ενιαίες κλάσεις και το εκπαιδευμένο μοντέλο περνά ως prediction function.
- AutoExplainer (omnixai.preprocessing & AutoExplainerBase): συνδυάζει το μοντέλο με τους κατάλληλους προ- και μετα-επεξεργαστές (π.χ. one-hot/ordinal encoding, normalization, rescale, TF-IDF), δημιουργεί αυτόματα τους επιλεγμένους explainers (όπως "shap", "pdp", "gradcam") και ορίζει αν η ερμηνεία θα είναι τοπική ή καθολική, agnostic ή specific.
- Explainers (omnixai.explainers): οι προκαθορισμένες κλάσεις TabularExplainer, VisionExplainer, NLPExplainer και TimeseriesExplainer καλύπτουν πίνακες (PDP, LIME, SHAP, MACE), εικόνες (Integrated Gradients, Grad-CAM, Contrastive Explanation, Counterfactual CE), κείμενο (LIME, Integrated Gradients) και χρονοσειρές, με όλες τις μεθόδους να είναι model-agnostic, λειτουργώντας απευθείας στα δεδομένα εκπαίδευσης. Κάθε explainer εκτελεί τις λειτουργίες Initialize και Explain, παράγοντας αντικείμενα Explanation.
- Plotting (omnixai.explanations): τα αντικείμενα Explanation ενσωματώνουν μεθόδους plot, plotly_plot και ipython_plot για άμεση οπτικοποίηση κάθε ερμηνείας, και
- Dashboard (omnixai.visualization): ένα διαδραστικό περιβάλλον όπου όλες οι γραφικές παραστάσεις συγκεντρώνονται για εύκολη σύγκριση και εξερεύνηση τοπικών και καθολικών εξηγήσεων.

3.3 Πείραμα «Δυνατότητα Προσομοίωσης»

Στην ενότητα αυτή παρουσιάζεται μια μεθοδολογική προσέγγιση για τη μέτρηση της ερμηνευσιμότητας ενός αλγορίθμου μέσω της διεξαγωγής δύο πειραμάτων με

ανθρώπινους συμμετέχοντες, με επίκεντρο την έννοια της «δυνατότητας προσομοίωσης» (simulatability). Η simulatability ορίζεται ως η ικανότητα των χρηστών να προβλέπουν τη συμπεριφορά ενός μοντέλου όταν έρχεται αντιμέτωπο με νέες εισόδους. Η πρώτη δοκιμή, γνωστή ως «προσομοίωση προς τα εμπρός» (forward simulation), ζητάει από τον χρήστη να προβλέψει την έξοδο του μοντέλου για μια νέα είσοδο, με ή χωρίς τη βοήθεια εξήγησης. Η δεύτερη, η «αντιπαραδειγματική προσομοίωση» (counterfactual simulation), καλεί τον χρήστη να προβλέψει πώς θα μεταβληθεί η έξοδος αυτού του μοντέλου εφόσον μεταβληθούν συγκεκριμένα χαρακτηριστικά της εισόδου, έχοντας στη διάθεσή του την αρχική πρόβλεψη και τη σχετική εξήγηση. Με αυτόν τον τρόπο, αξιολογείται η συμβολή των αλγοριθμικών εξηγήσεων στη βελτίωση της κατανόησης και της δυνατότητας πρόβλεψης της συμπεριφοράς του μοντέλου από τον τελικό χρήστη.

3.3.1 Forward Simulation

Η προσέγγιση της προσομοίωσης προς τα εμπρός περιλαμβάνει τέσσερα διακριτά στάδια. Αρχικά στη φάση εκμάθησης χωρίς εξήγηση, οι χρήστες παρατηρούν ένα σετ παραδειγμάτων με την είσοδο x , την πραγματική ετικέτα y και την πρόβλεψη του μοντέλου $y^{\wedge}$, ώστε να εξοικειωθούν με τη λειτουργία του μοντέλου χωρίς να λαμβάνουν επεξηγήσεις. Στη συνέχεια, στη φάση πρόβλεψης (Pre), δίνονται νέες εισόδους x_{test} και οι χρήστες καλούνται να προβλέψουν την έξοδο του μοντέλου y_{pre} πριν τους παρασχεθούν εξηγήσεις. Στην επόμενη φάση εκμάθησης με εξηγήσεις, οι χρήστες βλέπουν τα ίδια παραδείγματα αλλά πλέον συνοδεύονται από εξηγήσεις e . Ακολουθεί η φάση πρόβλεψης (Post), όπου οι χρήστες προβλέπουν εκ νέου για νέα δεδομένα x_{test} , έχοντας πλέον κατανοήσει τις εξηγήσεις.

Σχεδιαστικά, τα παραδείγματα που εξηγούνται διαχωρίζονται από εκείνα που χρησιμοποιούνται στη δοκιμή, ώστε οι εξηγήσεις να μην αποκαλύπτουν άμεσα τις σωστές απαντήσεις. Η απόδοση των χρηστών συγκρίνεται με και χωρίς εξηγήσεις στο ίδιο σύνολο δεδομένων, ενώ η επιλογή των παραδειγμάτων γίνεται έτσι ώστε το μοντέλο να έχει παρόμοια πιθανότητα σωστής και λανθασμένης πρόβλεψης, αποτρέποντας με αυτό τον τρόπο τις τυχαίες επιτυχίες. Επιπλέον, ζητείται από τους χρήστες να δώσουν προβλέψεις για όλα τα παραδείγματα, ώστε να διασφαλιστεί ότι η αξιολόγηση των εξηγήσεων δεν επηρεάζεται από την επιλογή μόνο εύκολων ή κατανοητών περιπτώσεων.

3.3.2 Counterfactual Simulation

Η αντιπαραδειγματική προσομοίωση αξιολογεί την ικανότητα των χρηστών να προβλέπουν τη συμπεριφορά του μοντέλου σε εναλλακτικά σενάρια εισόδων. Σε κάθε φάση, οι χρήστες παρατηρούν τις ίδιες αρχικές εισόδους, τις πραγματικές ετικέτες, την πρόβλεψη του μοντέλου και μια διαταραγμένη έκδοση της εισόδου. Κατά τη φάση πρόβλεψης (Pre), ο χρήστης βλέπει τις εισόδους και τις αντίστοιχες προβλέψεις $y^{\wedge}$ και καλείται να προβλέψει την έξοδο του μοντέλου για τις αντιπαραδειγματικές εισόδους x_c , δηλαδή ελαφρώς τροποποιημένες εκδοχές των αρχικών παραδειγμάτων.

Στη φάση πρόβλεψης (Post), αφού του παρασχεθούν οι απαραίτητες εξηγήσεις e για τις αρχικές εισόδους, ο χρήστης προβλέπει εκ νέου τις εξόδους για τις αντιπαραγοντικές x_c ,

αποτυπώνοντας την πρόβλεψη ως $y_{\sim post}$. Έτσι, ο χρήστης καλείται να εκτιμήσει πώς θα αλλάξει η απόφαση του μοντέλου αν μεταβληθούν συγκεκριμένα χαρακτηριστικά. Η επίδραση της συγκεκριμένης εξήγησης υπολογίζεται ως η διαφορά στην ακρίβεια του χρήστη πριν και μετά από την παροχή εξηγήσεων, αποτυπώνοντας έτσι το πόσο οι εξηγήσεις συνέβαλαν στη βελτίωση της κατανόησης και πρόβλεψης της συμπεριφοράς του μοντέλου.

3.3.3 Αξιολόγηση Αλγοριθμικών Εξηγήσεων

Για την αξιολόγηση των αλγοριθμικών εξηγήσεων, χρησιμοποιήθηκαν τόσο δεδομένα κειμένου (κριτικές ταινιών) όσο και δομημένα δεδομένα σε μορφή πινάκων (δημογραφικά στοιχεία), με σκοπό να εξεταστεί η αποτελεσματικότητα πέντε διαφορετικών μεθόδων εξήγησης. Τα αποτελέσματα έδειξαν ότι μόνο δύο μέθοδοι παρουσίασαν σαφή αποτελεσματικότητα, η μέθοδος LIME, η οποία ήταν αποδοτική αποκλειστικά στα δομημένα δεδομένα κατά την ταξινόμηση πινάκων, και η μέθοδος Prototype, που αποδείχθηκε ιδιαίτερα αποτελεσματική στην αντιπαραδειγματική προσομοίωση και για τα δύο είδη δεδομένων. Η μελέτη αποκάλυψε ακόμη ότι, όσον αφορά τα δεδομένα κειμένου, καμία μέθοδος δεν ξεχώρισε και στους δύο τύπους προσομοίωσης. Επιπλέον, διαπιστώθηκε ότι οι χρήστες τείνουν να αξιολογούν θετικά τις πιο σύνθετες εξηγήσεις, ωστόσο αυτές δεν ενίσχυσαν σε ουσιαστικό βαθμό τη δυνατότητα προσομοίωσης σε κανένα από τα δεδομένα που εξετάστηκαν.

3.3.4 Αποτελεσματικότητα Εξηγήσεων στην Κατανόηση

Οι αλγοριθμικές εξηγήσεις μπορούν να βελτιώσουν σημαντικά την κατανόηση των χρηστών σχετικά με τη συμπεριφορά του μοντέλου, κυρίως όταν εντοπίζουν και αναδεικνύουν με σαφήνεια τα κύρια χαρακτηριστικά που καθορίζουν την τελική πρόβλεψη. Για παράδειγμα, στη φράση «Pretty much sucks, but has a funny moment or two.», ακόμη και μετά από μικρές αντιπαραδειγματικές αλλαγές («Mostly just bothers, but looks a funny moment or two.»), το LIME εντοπίζει τις λέξεις "funny" και "moment" ως βασικούς θετικούς παράγοντες που διατηρούν την πρόβλεψη, ενώ η αλλαγή της αρνητικής λέξης "sucks" σε "bothers" δεν είναι αρκετή για να ανατρέψει το αποτέλεσμα. Παράλληλα, το Prototype model ενεργοποιεί ένα πρότυπο με παρόμοια χαρακτηριστικά και δομή, ενισχύοντας την προβλεψιμότητα του μοντέλου.

Αντίθετα, σε περιπτώσεις όπου η φράση μεταβάλλεται ουσιαστικά ως προς το νόημα (π.χ. από «A bittersweet film» σε «A teary film»), καμία μέθοδος εξήγησης δεν καταφέρνει να αποσαφηνίσει τα χαρακτηριστικά που οδήγησαν στην αλλαγή της πρόβλεψης. Το LIME αποδίδει χαμηλές τιμές βαρών σε αυτά, ενώ οι Decision Boundary και Prototype μέθοδοι δεν παρέχουν ξεκάθαρη εξήγηση για τον λόγο που άλλαξε το αποτέλεσμα. Αυτό υπογραμμίζει την ανάγκη για πιο αποτελεσματικές μεθόδους εξηγήσεων, που θα είναι ικανές να εμβαθύνουν, να απομονώνουν και να παρουσιάζουν τα στοιχεία που επηρεάζουν ουσιαστικά την απόφαση του μοντέλου, προσφέροντας έτσι διαφάνεια και αξιόπιστη υποστήριξη στη λήψη αποφάσεων.

3.3.5 Υποκειμενική Ικανοποίηση ως Δείκτης Πραγματικής Αξίας Εξηγήσεων

Κατά τη διάρκεια της αξιολόγησης, οι χρήστες κλήθηκαν να εκφράσουν υποκειμενικές κρίσεις τόσο στη φάση εκμάθησης όσο και μετά την παροχή εξηγήσεων, σημειώνοντας κατά πόσο κάθε εξήγηση τους βοήθησε να προβλέψουν τη συμπεριφορά του μοντέλου. Ωστόσο, τα αποτελέσματα φανέρωσαν ότι μια υψηλή υποκειμενική αξιολόγηση δεν συνδέεται απαραίτητα με αυξημένη ακρίβεια στις προβλέψεις. Η ανάλυση ανέδειξε ότι οι υποκειμενικές αξιολογήσεις δεν αποτελούν αξιόπιστο δείκτη της πραγματικής αποτελεσματικότητας μιας εξήγησης, δημιουργώντας συχνά μια ψευδαίσθηση κατανόησης. Το ζήτημα αυτό αναδεικνύει ένα καίριο ερώτημα: εφόσον η υποκειμενική ικανοποίηση του χρήστη δεν συνιστά ασφαλές κριτήριο, ποια αντικειμενικά μέτρα μπορούν να χρησιμοποιηθούν για την αξιολόγηση της πραγματικής αξίας μιας εξήγησης;

Η συνολική ανάλυση παρουσιάζει ότι πολλές μέθοδοι εξήγησης δεν ενισχύουν ουσιαστικά την κατανόηση της συμπεριφοράς του μοντέλου και ότι αυτή που αποδεικνύεται αποτελεσματική σε ένα πεδίο μπορεί να αποτύχει σε ένα άλλο. Σε αυτό το πλαίσιο, οι μετρικές προσομοιωσιμότητας προσφέρουν μια πιο αντικειμενική και αξιόπιστη αξιολόγηση της ερμηνευσιμότητας, καθώς μετρούν το κατά πόσο οι εξηγήσεις βελτιώνουν πραγματικά την ικανότητα του χρήστη να προβλέπει τη συμπεριφορά του συστήματος. Η διεξαγωγή αντίστοιχων πειραμάτων συνοδεύεται και από επιπρόσθετες προκλήσεις, όπως οι γνωστικοί περιορισμοί των χρηστών και η ανάγκη δημιουργίας ρεαλιστικών counterfactual παραδειγμάτων. Τα συνολικά ευρήματα που προκύπτουν, υπογραμμίζουν την ανάγκη για αυξημένη προσοχή στον τρόπο αξιολόγησης των εξηγήσεων και αναδεικνύουν το σημαντικό περιθώριο βελτίωσης που υπάρχει στις ήδη υπάρχουσες μεθόδους.

4. Ατομικότητα και Συλλογικότητα

4.1 Η Υπεροχή των Υπολογιστών

Οι μηχανές υπερέχουν των ανθρώπων σε διάφορα προβλήματα που είναι σαφώς καθορισμένα και δομημένα. Από τη δεκαετία του 1990, οι υπολογιστές έχουν καταφέρει να ξεπεράσουν κορυφαίους παίκτες σε πολύπλοκα παιχνίδια στρατηγικής, όπως είναι το σκάκι (νικώντας τον Γκάρι Κασπάροφ το 1997) και το Go (νίκη κατά του Λι Σεντόλ το 2016). Πιο αναλυτικά, στην επεξεργασία των πληροφοριών οι υπολογιστές είναι ταχύτεροι και πιο αξιόπιστοι από τους ανθρώπους σε αριθμητικούς υπολογισμούς, στην αποθήκευση και ανάκτηση τεράστιων όγκων δεδομένων, καθώς και στην αναζήτηση σε μεγάλες βάσεις δεδομένων.

Επιπλέον, η πρόοδος στη βαθιά μάθηση έχει επιτρέψει στην τεχνητή νοημοσύνη να ξεπεράσει τον άνθρωπο σε εργασίες όπως η αναγνώριση αντικειμένων σε εικόνες ή η ανίχνευση ελαττωμάτων σε γραμμές παραγωγής. Οι μηχανές είναι ταχύτερες και πιο ακριβείς από τους ανθρώπους και σε φυσικά καθήκοντα, καθώς δεν κουράζονται, δεν υπόκεινται σε συναισθηματικές μεταπτώσεις και δεν παρεκκλίνουν από τις εντολές που τους δίνονται. Αυτά τα χαρακτηριστικά, λοιπόν, τις καθιστούν ιδανικές για επαναλαμβανόμενες ή επικίνδυνες εργασίες, όπως σε γραμμές παραγωγής και τηλεφωνικά κέντρα, και σταδιακά οδηγούν στην αυτοματοποίηση επαγγελματιών που απαιτούν λήψη τυποποιημένων αποφάσεων, όπως εξυπηρέτηση πελατών και οδήγηση.

4.2 Η Μοναδικότητα του Ανθρώπου

Παρά την αλματώδη πρόοδο της τεχνητής νοημοσύνης και των υπολογιστών, οι μηχανές εξακολουθούν να έχουν σημαντικούς περιορισμούς στην επίλυση σύνθετων και ασαφών προβλημάτων, όπου η ανθρώπινη κρίση και δημιουργικότητα παραμένουν αναντικατάστατες. Ενώ οι μηχανές μπορούν να επιτύχουν επίπεδα ανάλυσης και ταχύτητας που προσεγγίζουν την ανθρώπινη όραση, οι άνθρωποι διατηρούν σημαντικά πλεονεκτήματα σε άλλες αισθήσεις όπως η όσφρηση, η αφή και η γεύση. Επιπλέον, ο ανθρώπινος εγκέφαλος διακρίνεται για την εξαιρετική ενεργειακή του αποδοτικότητα, καταναλώνοντας μόλις 40 watt για να εκτελέσει περίπου τέσσερα δισεκατομμύρια megaFLOPS, σε αντίθεση με τους σύγχρονους υπερυπολογιστές που απαιτούν πέντε εκατομμύρια watt για αντίστοιχη υπολογιστική ισχύ, καθιστώντας τον εγκέφαλο έως και 1.000 φορές πιο αποδοτικό.

Ένα εντυπωσιακό παράδειγμα φυσικής μνήμης αποτελεί το ανθρώπινο DNA, όπου κάθε ένα από τα περίπου έξι τρισεκατομμύρια κύτταρα του οργανισμού μας περιέχει το σύνολο των πληροφοριών για τη δημιουργία του σώματός μας. Το DNA παραμένει αδιαμφισβήτητο πιο συμπαγές και αξιόπιστο από κάθε ψηφιακό αποθηκευτικό μέσο, όπως καταδεικνύει η ανεύρεση άθικτων αλληλουχιών σε απολιθώματα άνω του ενός εκατομμυρίου ετών. Παράλληλα, οι φυσικές δεξιότητες, όπως η κινητικότητα και ευελιξία του ανθρώπινου χεριού, με τη σύνθετη δομή των οστών, μυών και τενόντων, επιτρέπουν κινήσεις απaráμιλλης πολυπλοκότητας και ακρίβειας, που οι μηχανές δύσκολα μπορούν να μιμηθούν.

Επιπλέον, οι άνθρωποι διαπρέπουν στο κομμάτι της δημιουργικότητας και στην επίλυση μη δομημένων προβλημάτων, όπου οι κανόνες δεν είναι προκαθορισμένοι. Παρά τις σημαντικές προσπάθειες των υπολογιστών να δημιουργήσουν τέχνη ή μουσική, η ανθρώπινη δημιουργικότητα και φαντασία παραμένουν ανώτερες και πιο εντυπωσιακές. Σε πιο δυναμικά περιβάλλοντα, όπως ένα νοσοκομείο με πολλαπλά πληροφοριακά συστήματα και αλληλεπιδρώντα workflows, ένας έμπειρος επαγγελματίας έχει τη δυνατότητα, με τη διαίσθηση και την εμπειρία του, να εντοπίσει γρήγορα την κατάλληλη λύση για την ενσωμάτωση νέου εξοπλισμού ή την αναδιοργάνωση διαδικασιών, κάτι που

θα απαιτούσε ώρες ή θα ήταν ανέφικτο για έναν αλγόριθμο. Εξίσου σημαντική είναι η ικανότητα των ανθρώπων για συνεργασία, διότι οι άνθρωποι δεν περιορίζονται στη συνεργασία με μέλη της οικογένειάς τους, αλλά εργάζονται μαζί για τη δημιουργία σύνθετων έργων και δομών, συμβάλλοντας συλλογικά σε τομείς όπως η επιστήμη, η τεχνολογία και η κοινωνία.

4.3 Συνεργασία Ανθρώπου και Μηχανής

Η βαθιά εξάρτηση των ανθρώπων από την τεχνολογία και η ικανότητά τους να την κατασκευάζουν και να τη χρησιμοποιούν, αποδεικνύουν ότι η επιβίωση και η πρόοδος όλων είναι άρρηκτα συνδεδεμένες με αυτή. Η τεχνολογία εξελίσσεται παράλληλα με τον άνθρωπο και η απώλειά της θα είχε άμεσες και σοβαρές επιπτώσεις σε κρίσιμους τομείς όπως η παραγωγή τροφής, η ενέργεια, η υγεία και η επικοινωνία. Αν και αρκετές έρευνες προβλέπουν την πλήρη αντικατάσταση του ανθρώπου από τις μηχανές, πολλές ανθρώπινες ικανότητες θα παραμείνουν ανώτερες για αρκετά χρόνια ακόμη.

Το μέλλον στην ουσία δεν βρίσκεται στον ανταγωνισμό, αλλά στη συνεργασία, δηλαδή οι υπολογιστές και τα συστήματα τεχνητής νοημοσύνης θα αναλαμβάνουν αριθμητικά, επαναληπτικά και αποθηκευτικά καθήκοντα, ενώ οι άνθρωποι θα επικεντρώνονται σε πιο σύνθετα, μη συνηθισμένα προβλήματα που απαιτούν διαίσθηση, εμπειρία και δημιουργικότητα. Η Εξηγήσιμη Τεχνητή Νοημοσύνη αποτελεί το εργαλείο κλειδί που θα επιτρέψει αυτή τη συνέργεια, καθιστώντας τις αποφάσεις των συστημάτων διαφανείς και ενισχύοντας την εμπιστοσύνη των ανθρώπων. Επιπλέον, θεωρείται ζωτικής σημασίας για την αντιμετώπιση πολύπλοκων παγκόσμιων προκλήσεων, όπως η θεραπεία του καρκίνου και η διατήρηση της παγκόσμιας ειρήνης, όπου η αποτελεσματική συνεργασία ανθρώπου και μηχανής είναι όχι μόνο επωφελής, αλλά και απολύτως αναγκαία.

4.4 Μαθαίνοντας από το Σκάκι

Το σκάκι, με την ασύλληπτη πολυπλοκότητά του, αποτέλεσε για δεκαετίες ένα εμβληματικό πεδίο πρόκλησης για την τεχνητή νοημοσύνη. Παρότι η νίκη του Deep Blue επί του Γκάρι Κασπάροφ το 1997 σηματοδότησε μια ιστορική καμπή, ανέδειξε επίσης μια νέα ιδέα, τη δύναμη της συνεργασίας μεταξύ ανθρώπου και μηχανής. Το πιο εντυπωσιακό παράδειγμα έγινε το 2005, όταν δύο ερασιτέχνες σκακιστές, χρησιμοποιώντας απλούς υπολογιστές, κατάφεραν να επικρατήσουν τόσο του υπερυπολογιστή Hydra όσο και κορυφαίων επαγγελματιών. Η επιτυχία τους βασίστηκε στον άρτιο συνδυασμό ανθρώπινης κρίσης και υπολογιστικής ισχύος, καθώς οι μηχανές εκτελούσαν εξαιρετικά τους αριθμητικούς υπολογισμούς και ανέλυναν τεράστιες ακολουθίες κινήσεων, ενώ οι άνθρωποι παρενέβαιναν όπου επικρατούσε αβεβαιότητα, αξιολογώντας και ερμηνεύοντας τα δεδομένα. Αυτή η μορφή συνεργασίας, που

συνδυάζει εμπειρία, αναστοχασμό και βαθιά κατανόηση του τρόπου σκέψης των μηχανών, αναδεικνύει τον δρόμο που πρέπει να ακολουθηθεί.

5. Τομείς Εφαρμογής

5.1 Επιχειρηματικές και Νομικές Διαστάσεις

5.1.1 Διαφάνεια, Λογοδοσία και Ενίσχυση Εμπιστοσύνης

Η διαφάνεια, η λογοδοσία και η ενίσχυση της εμπιστοσύνης αποτελούν θεμελιώδεις πυλώνες για τη λειτουργία και τη βιωσιμότητα κάθε σύγχρονης επιχείρησης, καλύπτοντας όλα τα επίπεδα της οργανωτικής δομής, από το προσωπικό πρώτης γραμμής έως το διοικητικό συμβούλιο. Με τη ραγδαία ενσωμάτωση των συστημάτων τεχνητής νοημοσύνης σε κρίσιμες διαδικασίες και τη μεταβίβαση ολοένα και περισσότερων αποφάσεων από τον άνθρωπο στις μηχανές, η ανάγκη για διαφάνεια και λογοδοσία μεταφέρεται πλέον και στα ίδια τα συστήματα ΑΙ. Από τις καταναλωτικές εφαρμογές, όπως το Google Maps, και τα εσωτερικά πληροφοριακά συστήματα (λογιστήριο, ανθρώπινο δυναμικό, μάρκετινγκ) έως τις βιομηχανικές πλατφόρμες, η τεχνητή νοημοσύνη δημιουργεί ένα νέο τοπίο προκλήσεων για τις επιχειρήσεις.

Αναδεικνύονται ταυτόχρονα διάφορα ζητήματα όπως η αξιοπιστία των συστάσεων των συστημάτων ΑΙ, η κατανομή της ευθύνης σε περιπτώσεις σφάλματος ή προκατάληψης και η διασφάλιση της ασφάλειας έναντι κακόβουλων παρεμβάσεων. Επιπλέον, τίθεται το ζήτημα του ρόλου που διαδραματίζει η ανθρώπινη παρέμβαση στη λήψη κρίσιμων αποφάσεων έναντι της αυτοματοποιημένης λειτουργίας των συστημάτων. Η πιο ορθή διαχείριση αυτών των θεμάτων αποτελεί βασική προϋπόθεση για την ενίσχυση της εμπιστοσύνης και την ευρεία αποδοχή της τεχνητής νοημοσύνης στον σύγχρονο επιχειρηματικό κόσμο.

5.1.2 Ανίχνευση Απάτης και Διαχείριση Κινδύνου

Η διαδικτυακή απάτη εξελίσσεται με ταχύτατους ρυθμούς, με τους δράστες να αξιοποιούν πλέον τεχνικές τεχνητής νοημοσύνης και να στοχεύουν σε μικρές αλλά επαναλαμβανόμενες συναλλαγές που διαφεύγουν από τους παραδοσιακούς μηχανισμούς ελέγχου. Οι συμβατικοί αλγόριθμοι ανίχνευσης, οι οποίοι βασίζονται κυρίως στον εντοπισμό ανωμαλιών, δεν είναι πάντα επαρκείς. Μια απλή απόκλιση από τη συνήθη συμπεριφορά μπορεί να είναι απολύτως νόμιμη, ενώ τα ψευδώς θετικά αποτελέσματα οδηγούν σε απώλεια εμπιστοσύνης από τους πελάτες.

Η ΧΑΙ προσφέρει τη δυνατότητα παροχής ερμηνειών για κάθε ύποπτη συναλλαγή, αναλύοντας τα μοτίβα που ενισχύουν ή αποδυναμώνουν την πιθανότητα απάτης και επιτρέποντας έτσι πιο αυστηρό αλλά και δίκαιο έλεγχο χωρίς να επιβαρύνονται οι αθώοι

χρήστες. Στον χρηματοπιστωτικό τομέα, όπου η διαφάνεια αποτελεί κρίσιμη απαίτηση, αυτού του είδους οι λύσεις γίνονται ολοένα και πιο απαραίτητες. Ένα ενδεικτικό παράδειγμα είναι η ισραηλινή εταιρεία ThetaRay, που με την πλατφόρμα SONAR χρησιμοποιεί προηγμένους αλγόριθμους για την ανίχνευση άγνωστων απειλών σε διασυννοριακές πληρωμές και παρέχει παράλληλα επεξηγήσεις για τις ανιχνεύσιμες ανωμαλίες, ενισχύοντας την εμπιστοσύνη των χρηστών. Τέτοιες προσεγγίσεις αποτελούν το νέο πρότυπο της αγοράς, συστήματα τα οποία όχι μόνο ανιχνεύουν την απάτη, αλλά εξηγούν και τους λόγους εντοπισμού της, προάγοντας τη διαφάνεια, τη συμμόρφωση και την αποτελεσματικότητα στη διαχείριση κινδύνου.

5.1.3 Νομικές Προκλήσεις και Ρυθμιστικό Πλαίσιο

Ο Γενικός Κανονισμός Προστασίας Δεδομένων (GDPR), που ισχύει από τον Μάιο του 2018, επιβάλλει αυστηρές κυρώσεις για μη συμμόρφωση, με πρόστιμα που φτάνουν έως και τα €20 εκατομμύρια ή το 4% του ετήσιου παγκόσμιου κύκλου εργασιών, όποιο από τα δύο είναι μεγαλύτερο. Οι μεγάλες επιχειρήσεις διατρέχουν σοβαρούς κινδύνους εάν δεν τηρούν τα πρότυπα διαφάνειας και προστασίας προσωπικών δεδομένων. Ειδικά το «Δικαίωμα Εξήγησης» (Άρθρο 22 του GDPR) διασφαλίζει ότι κανείς δεν μπορεί να υφίσταται αποφάσεις που τον αφορούν (όπως απόρριψη δανείου ή ασφάλισης) αποκλειστικά βάσει αυτοματοποιημένων διαδικασιών χωρίς ανθρώπινη παρέμβαση.

Επιπλέον, σε περιπτώσεις αποφάσεων με σημαντικές επιπτώσεις (νομικές, οικονομικές κ.λπ.), οι πολίτες έχουν το δικαίωμα να ζητήσουν ανθρώπινη αξιολόγηση της περίπτωσης τους, να λάβουν εξήγηση για τον τρόπο και τους λόγους λήψης της απόφασης, καθώς και να την αμφισβητήσουν. Συνοψίζοντας, ο κανονισμός επηρεάζει όλες τις επιχειρήσεις παγκοσμίως, καθώς καλύπτει τόσο τα δεδομένα που χρησιμοποιούνται από ευρωπαϊκούς οργανισμούς όσο και αυτά που επεξεργάζονται οργανισμοί εκτός Ευρώπης, καθιστώντας την εξηγήσιμη τεχνητή νοημοσύνη απαραίτητη για τη συμμόρφωση με το σύγχρονο ρυθμιστικό πλαίσιο.

5.2 Κρίσιμοι Τομείς

5.2.1 Βελτιώνοντας τη Διάγνωση και τη Φροντίδα Ασθενών

Η τεχνητή νοημοσύνη έχει ήδη αρχίσει να διαδραματίζει καθοριστικό ρόλο στον τομέα της ιατρικής, ενισχύοντας τους επαγγελματίες υγείας μέσω της ικανότητάς της να επεξεργάζεται και να αναλύει μεγάλα και πολύπλοκα σύνολα δεδομένων. Η αξιοποίησή της σε ειδικότητες όπως η ογκολογία, η παθολογία και η διάγνωση σπάνιων παθήσεων συμβάλλει ουσιαστικά στη βελτίωση της ακρίβειας και της ταχύτητας στη λήψη κλινικών αποφάσεων. Ωστόσο, η πλήρης αντικατάσταση του ιατρού σε αποφάσεις κρίσιμης σημασίας, ειδικά σε θέματα ζωής και θανάτου, παραμένει ανέφικτη, καθώς δεν υπάρχει πλήρης κατανόηση του τρόπου λειτουργίας και των εσωτερικών μηχανισμών των συστημάτων AI. Σε αυτά τα πλαίσια, η τεχνητή νοημοσύνη λειτουργεί επικουρικά,

προσφέροντας σημαντική υποστήριξη στους κλινικούς ιατρούς, οι οποίοι διατηρούν πάντοτε την τελική ευθύνη για τη λήψη αποφάσεων.

Ταυτόχρονα, προσδίδει πολύ μεγάλη αξία στον ιατρικό τομέα, ενισχύοντας τη διαφάνεια και την κατανόηση των συστάσεων που προκύπτουν από τα συστήματα ΑΙ. Αυτή η διαφάνεια ενδυναμώνει την εμπιστοσύνη τόσο των ιατρών όσο και των ασθενών, διασφαλίζοντας ότι οι προτάσεις που προκύπτουν είναι επαρκώς τεκμηριωμένες, κατανοητές και λειτουργούν πάντα προς το συμφέρον του ασθενούς. Η εμπιστοσύνη αυτή αποτελεί κρίσιμο παράγοντα για την ευρύτερη υιοθέτηση και εδραίωση της τεχνητής νοημοσύνης στην υγειονομική περίθαλψη. Επιπλέον, η ΧΑΙ συμβάλλει στην ενίσχυση της ανθρωποκεντρικής επικοινωνίας, διευκολύνοντας τη μετάδοση ευαίσθητων ιατρικών πληροφοριών με τρόπο προσωπικό, αντί της απρόσωπης και ψυχρής πληροφόρησης που χαρακτηρίζει τις παραδοσιακές υπολογιστικές απαντήσεις.

Παρά τη χρησιμότητά της, η ΑΙ ενδέχεται να παρουσιάσει σφάλματα λόγω ελλείπων ή μεροληπτικών δεδομένων. Για παράδειγμα, αν ένα μοντέλο έχει εκπαιδευτεί σε έναν πληθυσμό συγκεκριμένης φυλής, οι προβλέψεις του μπορεί να είναι ανακριβείς για άλλες ομάδες. Η ΧΑΙ επιτρέπει τον εντοπισμό αυτών των συστημικών στρεβλώσεων, συμβάλλοντας στην αξιοπιστία των αποτελεσμάτων που παρέχει η τεχνητή νοημοσύνη. Επιπλέον, σε μια παραδοσιακή κλινική επίσκεψη, ο ασθενής έχει τη δυνατότητα να ρωτήσει τον γιατρό «Γιατί πιστεύετε ότι είναι καρκίνος;» ή «Πόσο σίγουροι είστε;», όπου ο γιατρός αξιοποιεί τη γνώση του ή τη συνεργασία του με ειδικό για να τεκμηριώσει ορθά την απόφασή του.

Αντίθετα, ένα συμβατικό σύστημα ΑΙ απλώς επιστρέφει μια πρόβλεψη χωρίς αιτιολόγηση, όπως «Κακοήθεια: 87%», χωρίς επεξηγηματικό πλαίσιο, οδηγώντας σε μεγαλύτερη σύγχυση και δυσπιστία. Ένα σύστημα ΧΑΙ μπορεί να τεκμηριώνει τις προβλέψεις του παρουσιάζοντας επισημασμένες περιοχές της ακτινογραφίας, ποσοστά εμπιστοσύνης και διαγράμματα αιτιολόγησης, υποστηρίζοντας τους γιατρούς στο κομμάτι της διάγνωσης και της θεραπείας. Έτσι, η ερμηνευσιμότητα καθίσταται βασικό θεμέλιο για τις αυτόματες αποφάσεις, ιδίως σε περιπτώσεις υψηλού κινδύνου, επιτρέποντας στον γιατρό να εξηγήσει με σαφήνεια και στον ασθενή να κατανοεί καλύτερα τη διάγνωση, ενισχύοντας ουσιαστικά την ενσωμάτωση της τεχνητής νοημοσύνης στην ιατρική πρακτική.

5.2.2 Ψηφιακός Μετασχηματισμός στο Μάρκετινγκ και τις Πωλήσεις

Η ραγδαία αύξηση των διαθέσιμων δεδομένων και η ψηφιοποίηση των κρίσιμων επιχειρησιακών διαδικασιών έχουν αναδιαμορφώσει το τοπίο του σύγχρονου μάρκετινγκ. Διάφορες πλατφόρμες αυτοματοποίησης, όπως το HubSpot, και προηγμένα συστήματα διαχείρισης πελατειακών σχέσεων (CRM) συμβάλλουν καθοριστικά στην εξατομίκευση και στη βελτιστοποίηση του κύκλου πωλήσεων. Τα συγκεκριμένα εργαλεία αξιοποιούν τεχνητή νοημοσύνη (ΑΙ) για να ενισχύσουν τη στόχευση, να προβλέψουν συμπεριφορές και να μεγιστοποιήσουν την αποτελεσματικότητα. Ωστόσο, η αδυναμία των παραδοσιακών συστημάτων ΑΙ να εξηγήσουν τις αποφάσεις τους, αφήνει τους marketers να εφαρμόζουν στρατηγικές χωρίς να διαθέτουν πλήρη κατανόηση του πώς και γιατί

λειτουργούν οι προτάσεις των μοντέλων. Η ανάγκη για μεγαλύτερη διαφάνεια καθιστά επιτακτική την υιοθέτηση εξηγήσιμων μηχανισμών τεχνητής νοημοσύνης, οι οποίοι βελτιώνουν την τεκμηρίωση των αποφάσεων, αυξάνουν την ακρίβεια των παρεμβάσεων και επιτρέπουν μια πιο δυναμική στρατηγική προσαρμογή.

Αντίστοιχα, στον τομέα των πωλήσεων, η ΧΑΙ λειτουργεί ως στρατηγικός σύμμαχος, παρέχοντας τεκμηριωμένες εξηγήσεις για κάθε προτεινόμενη ενέργεια ή εκτίμηση. Ειδικά στην πώληση υψηλής αξίας αγαθών, η ανάγκη για ακρίβεια και προσαρμοστικότητα είναι καθοριστική. Σε διαδικτυακά περιβάλλοντα, όπως το online shopping, η ΧΑΙ εξηγεί τους λόγους πίσω από κάθε πρόταση, ενώ με διαδραστικά εργαλεία, όπως τα chatbots, βοηθά στη βαθύτερη κατανόηση των καταναλωτικών μοτίβων. Η ευθυγράμμιση μάρκετινγκ και πωλήσεων μέσω ΧΑΙ οδηγεί σε πιο κατάλληλα αποτελέσματα, επιτρέποντας μια διαφανή ανταλλαγή πληροφορίας και μια ευέλικτη προσαρμογή σε σύνθετες και απρόβλεπτες ανθρώπινες συμπεριφορές.

5.2.3 Εκπαίδευση και Ηθικές Προεκτάσεις

Η τεχνητή νοημοσύνη στην εκπαίδευση δημιουργεί νέες ευκαιρίες για εξατομικευμένη μάθηση, αναπτύσσοντας μερικά προσαρμοστικά συστήματα που αναγνωρίζουν τις αδυναμίες και τις δυνατότητες των μαθητών, προσαρμόζοντας το εκπαιδευτικό περιεχόμενο στις ανάγκες τους και βελτιώνοντας τις γνωστικές τους ικανότητες μέσω στοχευμένης καθοδήγησης και ανατροφοδότησης. Αυτή η αυτοματοποίηση των μαθησιακών δραστηριοτήτων ενισχύει τόσο το έργο των εκπαιδευτικών όσο και την αποδοτικότητα των εκπαιδευτικών ιδρυμάτων.

Ωστόσο, η αυξανόμενη πολυπλοκότητα αυτών των συστημάτων γεννά ανησυχίες σχετικά με τη διαφάνεια, τη δικαιοσύνη και την ηθική, καθώς μαθητές και εκπαιδευτικοί συχνά δυσκολεύονται να κατανοήσουν τη λειτουργία των αλγορίθμων και να εκτιμήσουν τον πραγματικό τους αντίκτυπο στη μαθησιακή διαδικασία. Η έλλειψη διαφανούς εξήγησης και επαρκούς ανατροφοδότησης δυσχεραίνει την εμπιστοσύνη στις αποφάσεις που επηρεάζουν την εκπαιδευτική πρόοδο. Παρά τη διαθεσιμότητα ποικίλων εργαλείων ερμηνευσιμότητας, η κατανόηση των συστημάτων ΑΙ εξακολουθεί να είναι δύσκολη για τους μη ειδικούς, ενώ απαιτείται περαιτέρω έρευνα για να διασφαλιστεί μια πιο δίκαιη και ηθική ενσωμάτωση της ΧΑΙ στην εκπαιδευτική διαδικασία.

6. Δωδεκάλογος Επόμενων Βημάτων και

Μελλοντικών Βελτιώσεων

6.1 Δημιουργία Εξηγήσεων για Νέους Τύπους Τεχνητής Νοημοσύνης

Ιδιαίτερη πρόκληση για το πεδίο της ερμηνευσιμότητας αποτελούν τα γενετικά μοντέλα μεγάλης κλίμακας με δισεκατομμύρια παραμέτρους, όπου οι παραδοσιακές μέθοδοι ΧΑΙ, που είναι σχεδιασμένες κυρίως για κλασικά προβλήματα ταξινόμησης και παλινδρόμησης, δεν είναι πλέον επαρκείς. Μοντέλα όπως το GPT χαρακτηρίζονται από τεράστια υπολογιστική κλίμακα και πολυπλοκότητα, γεγονός που δυσχεραίνει σημαντικά την ανάλυση των εσωτερικών τους δομών και την εξαγωγή νοημάτων. Καθώς το μέγεθός τους αυξάνεται, η ανάλυση και η εις βάθος κατανόηση όσων έχουν μάθει γίνεται ολοένα και δυσκολότερη λόγω των δισεκατομμυρίων παραμέτρων που διαθέτουν βάρη μεταξύ τεχνητών νευρώνων, ενώ η πολυσημική φύση των νευρώνων, δηλαδή το ότι ένας νευρώνας μπορεί να εμπλέκεται σε πολλαπλές σημασιολογικές έννοιες ταυτόχρονα, περιπλέκει ακόμα περισσότερο τη διαδικασία ερμηνείας της λειτουργίας τους. Για παράδειγμα, ένας νευρώνας μπορεί σε ορισμένα συμφραζόμενα να αναγνωρίζει γάτες, ενώ σε άλλα να ανταποκρίνεται σε διαφορετικές και άσχετες έννοιες.

Η ανάλυση των λανθανόντων χώρων που μαθαίνουν αυτά τα μοντέλα και η παραγωγή πιο προσιτών εξηγήσεων για τα εσωτερικά τους μοτίβα παραμένουν εξαιρετικά δύσκολες, ενώ η κατανόηση του τρόπου με τον οποίο οι νόμοι κλιμάκωσης (scaling laws) επηρεάζουν τις επιδόσεις των μεγάλων γλωσσικών μοντέλων σε συγκεκριμένες εργασίες αποτελεί μια ακόμη σημαντική πρόκληση. Τα αποτελέσματα των scaling laws συχνά είναι απρόβλεπτα, καθιστώντας δύσκολη την εξαγωγή ασφαλών συμπερασμάτων σχετικά με το τι έχουν πραγματικά μάθει τα μοντέλα ή με την ποιότητα της εκπαίδευσής τους. Ως πιθανές λύσεις προτείνονται η μηχανιστική ερμηνευσιμότητα (mechanistic interpretability), η οποία στοχεύει στην εις βάθος κατανόηση των εσωτερικών αλγορίθμων και των νόμων κλιμάκωσης μέσω reverse engineering, καθώς και η πληροφοριακή γεωμετρία (information geometry) για την ανάλυση των χωρών υψηλής διάστασης, συνδυαστικά με την επιβολή κατάλληλων περιορισμών κατά την εκπαίδευση και λειτουργία των LLMs.

6.2 Αντιμετώπιση Περιορισμών

Παρά τις σημαντικές προόδους και τη χρησιμότητα των υπάρχουσών τεχνικών, μέθοδοι όπως οι χάρτες θερμότητας και οι τεχνικές κατανομής χαρακτηριστικών παρουσιάζουν ευαισθησία στις παραμετροποιήσεις και συχνά παραμένουν δυσνόητες για μη ειδικούς χρήστες. Επιπλέον, οι προσεγγίσεις σύνθεσης παραδειγμάτων μπορεί να εισάγουν

τεχνητά ή παραπλανητικά στοιχεία, μειώνοντας την αξιοπιστία των εξηγήσεων. Η αντιμετώπιση αυτών των αδυναμιών απαιτεί την ανάπτυξη συνδυαστικών και πιο ανθεκτικών τεχνικών, οι οποίες θα αξιοποιούν τα πλεονεκτήματα διαφόρων μεθόδων και θα οδηγούν σε πιο σταθερές και πειστικές ερμηνείες.

Οι τρέχουσες αυτές ερευνητικές προσπάθειες επικεντρώνονται σε τρεις κύριους άξονες. Πρώτον, στην ενίσχυση και βελτιστοποίηση των μεθόδων απόδοσης σημασίας μέσω πολυπαραμετρικών προσεγγίσεων, δεύτερον την εξάλειψη τεχνητών στοιχείων στις συνθετικές εξηγήσεις με τη χρήση προηγμένων γενετικών μοντέλων και τεχνικών ανακατασκευής, και τέλος την ανάπτυξη ανθεκτικών ερμηνειών που παραμένουν σταθερές σε μικρές διαταραχές των εισόδων. Η έμφαση στην ανθεκτικότητα τόσο των εξηγήσεων όσο και των ίδιων των μοντέλων, η ποσοτικοποίηση της αβεβαιότητας και η συνεχής ανατροφοδότηση αποτελούν τα βασικά εργαλεία για την αντιμετώπιση των ανοιχτών προκλήσεων της ερμηνευσιμότητας.

6.3 Αξιολόγηση Μεθόδων και Εξηγήσεων

Επειδή δεν υπάρχει ένα χρυσό πρότυπο για το τι εκλαμβάνεται ως μια καλή εξήγηση, η διαδικασία αξιολόγησης των μεθόδων ΧΑΙ συχνά περιορίζεται σε τεχνικά κριτήρια απόδοσης, παραμερίζοντας τη διάδραση με τον τελικό χρήστη. Η έλλειψη εμπειρικών μελετών που περιλαμβάνουν ανθρώπους ως συμμετέχοντες δυσχεραίνει τη σύγκριση μεταξύ διαφορετικών προσεγγίσεων και την ανάπτυξη πρακτικών κριτηρίων ποιότητας, ενώ όσες μελέτες υπάρχουν, χαρακτηρίζονται συνήθως από μικρή αντιπροσωπευτικότητα και στατιστικές αδυναμίες. Για την αντιμετώπιση αυτών των περιορισμών, είναι απαραίτητη η υιοθέτηση μιας διεπιστημονικής προσέγγισης που θα ενώνει ειδικούς της μηχανικής μάθησης, της αλληλεπίδρασης ανθρώπου-υπολογιστή και των κοινωνικών επιστημών. Εξίσου σημαντική είναι η ανάπτυξη τυποποιημένων πλαισίων και μετρικών αξιολόγησης, όπως το πλαίσιο Quantus και τα δημόσια σύνολα δεδομένων με ground truth, ώστε να διασφαλίζεται η αντικειμενική και επαναλήψιμη σύγκριση των μεθόδων ΧΑΙ. Επιπρόσθετα, η ενίσχυση της ανθρώπινης διάστασης απαιτεί τη συστηματική διεξαγωγή εμπειρικών μελετών, τη χρήση συνθετικών δεδομένων και εικονικών συμμετεχόντων και τη θέσπιση διαφανών πρωτοκόλλων και αυστηρών μεθοδολογιών που θα ενισχύουν τη σταθερότητα και την αξιοπιστία των αποτελεσμάτων. Τέλος, η δημιουργία ευρετικών και προτύπων θα διευκολύνει τον αποτελεσματικότερο σχεδιασμό και την εφαρμογή συστημάτων ΧΑΙ στην πράξη.

6.4 Η Εννοιολογική Ασάφεια του Όρου «Εξηγήσιμο»

Ο όρος «εξηγήσιμο» παραμένει ασαφής και πολυσήμαντος, καθώς μπορεί να αναφέρεται τόσο στην κατανόηση των λεπτομερών ενεργειών ενός αλγορίθμου όσο και σε πιο

αφηρημένες έννοιες, όπως η λογική και η αιτιολόγηση των αποφάσεών του. Στη βιβλιογραφία συναντάται μια διάκριση μεταξύ των όρων «ερμηνεύσιμο» και «εξηγήσιμο». Η Rudin (2019) συνδέει την ερμηνευσιμότητα με υπολογισμούς που είναι άμεσα κατανοητοί, εκφράζοντας σκεπτικισμό για τις post-hoc εξηγήσεις, ενώ οι Doshi-Velez και Kim (2017) ορίζουν την ερμηνευσιμότητα ως το σύνολο των επιθυμητών ιδιοτήτων, που μπορούν να ενισχυθούν μέσω κατάλληλων μεθόδων εξήγησης. Γενικότερα, η ερμηνευσιμότητα αναφέρεται στην ικανότητα εξαγωγής ουσιαστικής πληροφορίας από ένα μοντέλο μηχανικής μάθησης σχετικά με τις σχέσεις και τα μοτίβα που έμαθε κατά την εκπαίδευση, δηλαδή στο να καταδεικνύει ποιες μεταβλητές ή συνδυασμοί δεδομένων επηρεάζουν την πρόβλεψη και πώς (π.χ. αν το κάπνισμα, η ηλικία ή η χοληστερίνη συμβάλλουν περισσότερο στον υπολογισμό καρδιαγγειακού κινδύνου). Με άλλα λόγια, χαρτογραφεί τις εσωτερικές διεργασίες του αλγορίθμου.

Αντίθετα, η εξηγησιμότητα προχωρά ένα βήμα παραπέρα, καθώς μετατρέπει τη γνώση που κρύβεται στα μαθηματικά του μοντέλου σε πιο κατανοητά για τον άνθρωπο παραδείγματα, γεφυρώνοντας το χάσμα μεταξύ τεχνικής λειτουργίας και ανθρώπινης κατανόησης, μέσω διαγραμμάτων ή μεταφορών που διευκολύνουν την επικοινωνία των αποφάσεων του συστήματος. Παρά τις διαφορετικές προσεγγίσεις που επικρατούν, υπάρχει ευρεία συναίνεση ότι ένα εξηγήσιμο σύστημα θα πρέπει να προσφέρει διαφάνεια ως προς τα δυνατά και αδύναμα σημεία του, να ενισχύει την εμπιστοσύνη των χρηστών, να αποκαλύπτει τις παραμέτρους που επηρέασαν τις αποφάσεις, να καθιστά σαφή τη λογική των επιλογών και να αναγνωρίζει πιθανά λάθη, διασφαλίζοντας μια αμερόληπτη λειτουργία. Ωστόσο, παραμένει ανοιχτό το ερώτημα για το «πόση λεπτομέρεια είναι αρκετή», με αρκετούς ειδικούς να προτείνουν εναλλακτικούς όρους όπως «δικαιολογήσιμο», «υπεύθυνο» ή «διαφανές», θεωρώντας ότι εκφράζουν καλύτερα την ανάγκη για λογική αιτιολόγηση, υπευθυνότητα και εμπιστοσύνη.

6.5 Πολυδιάστατη Εξηγησιμότητα

Η πολυδιάστατη εξηγησιμότητα καθίσταται ως η βασική προτεραιότητα, καθώς οι εξηγήσεις που παρέχονται καλό είναι να συνδυάζουν παραμέτρους όπως η ασφάλεια, η δικαιοσύνη, η λογοδοσία και η αξιοπιστία. Δεν έχει νόημα να εξηγείται μια απόφαση εάν το μοντέλο δεν πληροί αυτά τα κριτήρια, αλλά αντίθετα όλες οι διαστάσεις της αξιοπιστίας οφείλουν να παρουσιάζονται συνδυαστικά, μέσα από μία ενιαία και ουσιαστική εξήγηση που να δικαιολογεί τόσο τη λειτουργία του συστήματος όσο και το επίπεδο εμπιστοσύνης που αξίζει. Η απουσία αντίστοιχων στοιχείων μπορεί να οδηγήσει σε εσφαλμένη εκτίμηση της αξιοπιστίας από τους χρήστες, ιδιαίτερα σε περιβάλλοντα αβεβαιότητας ή ταχείας μεταβολής.

Για την αντιμετώπιση αυτών των προκλήσεων, η ανάπτυξη μετρικών που ενσωματώνουν όλες τις διαστάσεις της αξιοπιστίας αποτελεί σημαντικό βήμα. Η ΧΑΙ έχει τη δυνατότητα να προσαρμόζει το βάθος και το είδος των εξηγήσεων ανάλογα με το επίπεδο

εγκυρότητας. Λιγότερο αξιόπιστα συστήματα παρέχουν λεπτομερείς τεκμηριώσεις, ενώ τα πιο αξιόπιστα αρκούνται σε συνοπτικές εξηγήσεις. Η έμφαση στις ανάγκες του χρήστη και η διαφάνεια στη διαδικασία αξιολόγησης ενισχύουν περαιτέρω την εμπιστοσύνη, ενώ ένας νέος, σαφής ορισμός της εξηγησιμότητας διευκολύνει τη χρήση ποσοτικών μεθόδων και την αξιοπιστία της αξιολόγησης.

6.6 Εστίαση στον Άνθρωπο

Οι εξηγήσεις πρέπει να είναι κατανοητές και σχετικές με τον άνθρωπο. Οι παραδοσιακές μέθοδοι, όπως οι χάρτες θερμότητας ή οι αποδόσεις χαρακτηριστικών, συχνά δεν εξυπηρετούν τις ανάγκες των μη ειδικών χρηστών, παραμένοντας σε ένα περισσότερο τεχνικό και αφηρημένο επίπεδο. Η εστίαση σε εννοιοκεντρικές και αφηγηματικές προσεγγίσεις, όπου οι εξηγήσεις διατυπώνονται με απλούς, γνώριμους όρους, παρέχουν παραδείγματα και παρουσιάζουν τα δεδομένα με διαφορετικούς τρόπους, καθιστώντας τις εξηγήσεις πιο εύχρηστες και προσβάσιμες για τους ανθρώπους. Εξίσου σημαντικό είναι οι εξηγήσεις να προσαρμόζονται δυναμικά όταν αλλάζουν οι ανάγκες και οι κανόνες, ενώ η σαφήνεια στο «γιατί» πίσω από κάθε απόφαση και η κατανόηση των αιτιακών συσχετίσεων είναι καθοριστικής σημασίας για τη χρησιμότητα των εξηγήσεων.

Αρκετές από τις σημερινές μεθόδους περιορίζονται στο να παρουσιάζουν απλές συσχετίσεις, χωρίς να προσφέρουν ουσιαστική πρακτική βοήθεια. Η σύγχρονη έρευνα προσπαθεί να ξεπεράσει αυτό το όριο, ενισχύοντας τη σύνδεση αιτίας-αποτελέσματος με τη χρήση αιτιακών μοντέλων και αντιπαραδειγμάτων. Νέες τεχνολογίες, όπως τα generative models, επιτρέπουν την παραγωγή εναλλακτικών εκδοχών και παραδειγμάτων που καθιστούν τις εξηγήσεις πιο κατανοητές, ενώ η ενσωμάτωση συμβολικής γνώσης (κανόνες, σύμβολα, λογικές σχέσεις) βοηθάει στην αναπαράσταση της γνώσης με τρόπο παρόμοιο με τον ανθρώπινο.

Παράλληλα, οι άνθρωποι δυσκολεύονται να εξηγήσουν πλήρως τις επιλογές τους, αφού πολλές αποφάσεις βασίζονται σε συναισθηματικούς, ασυνείδητους ή μη απολύτως λογικούς παράγοντες. Αφού ληφθεί μια απόφαση, τείνουν να αναζητήσουν εκ των υστέρων «λογικούς» λόγους για να τη δικαιολογήσουν. Το χάσμα ανάμεσα στη ρεαλιστική διαδικασία λήψης αποφάσεων που διαμορφώνεται από ασυνείδητες, συναισθηματικές και ενστικτώδεις διεργασίες και τη μεταγενέστερη, φαινομενικά καθαρή λογική αφήγηση, δείχνει ότι οι εκ των υστέρων λογικές ερμηνείες λειτουργούν ως post-hoc ρητορικές κατασκευές. Εφόσον δεν γίνεται να παρουσιαστεί με ακρίβεια το ανθρώπινο σκεπτικό, είναι αυξημένη η απαίτηση από τα συστήματα τεχνητής νοημοσύνης να το πραγματοποιούν με μεγαλύτερη ακρίβεια, γεγονός που θέτει υπό αμφισβήτηση τις προσδοκίες για την εξηγησιμότητα της ΑΙ.

6.7 Προσαρμογή σε διαφορετικούς αποδέκτες, πεδία και

στόχους

Οι εξηγήσεις που παρέχονται από τα συστήματα τεχνητής νοημοσύνης χρειάζεται να λαμβάνουν υπόψη τις ανάγκες, το υπόβαθρο και τις προσδοκίες κάθε χρήστη, είτε πρόκειται για τεχνικό, επιχειρηματία ή απλό χρήστη. Επιπλέον, κάθε πεδίο εφαρμογής όπως η υγεία, η αυτόνομη οδήγηση ή τα οικονομικά διαθέτει τις δικές του ιδιαιτερότητες όσον αφορά το περιεχόμενο και το απαιτούμενο βάθος των εξηγήσεων. Η ανάπτυξη κατάλληλων μοντέλων εξήγησης, η αξιοποίηση σχετικής γνώσης και η εισαγωγή διαδραστικών και εξατομικευμένων μεθόδων συμβάλλουν στην αύξηση της κατανόησης και της χρησιμότητας των εξηγήσεων.

Εξίσου σημαντική είναι η προσαρμογή των εξηγήσεων στους επιμέρους στόχους κάθε αποδέκτη, καθώς επιστημονικές δεδομένων, ρυθμιστικές αρχές και τελικοί χρήστες ενδιαφέρονται για τελείως διαφορετικές διαστάσεις της εξηγησιμότητας από τεχνικές λεπτομέρειες και αξιολόγηση αμεροληψίας, μέχρι απλές και φιλικές εξηγήσεις για τις αποφάσεις που τους αφορούν. Με αυτόν τον τρόπο διασφαλίζεται ότι κάθε χρήστης λαμβάνει τις πληροφορίες που του είναι πραγματικά χρήσιμες, ενισχύοντας τη διαφάνεια και την εμπιστοσύνη προς τα συστήματα τεχνητής νοημοσύνης.

6.8 Υπερβολική Πολυπλοκότητα

Καθώς η τεχνητή νοημοσύνη εξελίσσεται, τα συστήματα γίνονται ολοένα και πιο πολύπλοκα, δημιουργώντας έναν σημαντικό περιορισμό στην εξηγησιμότητα, καθώς ακόμη και οι πιο απλές εξηγήσεις ενδέχεται να είναι υπερβολικά περίπλοκες για να γίνουν κατανοητές, ακόμη και από ειδικούς. Η αυξανόμενη υπολογιστική και εννοιολογική πολυπλοκότητα καθιστά τις εξηγήσεις λιγότερο προσιτές και χρήσιμες για τον τελικό χρήστη. Η κατάσταση αυτή θυμίζει τον Αϊνστάιν που προσπαθεί να εξηγήσει σε παιδιά νηπιαγωγείου τη θεωρία της σχετικότητας. Όσο κι αν απλοποιήσει τις έννοιες, ζητήματα όπως «τρεις διαφορετικοί παρατηρητές, τρεις διαφορετικές πραγματικότητες» ή «ο χρόνος και ο χώρος είναι σχετικοί με την κινητική σου κατάσταση» παραμένουν ακατανόητα. Αντίστοιχα, στην Εξηγήσιμη Τεχνητή Νοημοσύνη, όταν το γνωστικό χάσμα μεταξύ συστήματος και χρήστη είναι μεγάλο, οι εξηγήσεις χάνουν την αξία τους, καθώς δεν μπορούν να γεφυρώσουν τη διαφορά κατανόησης και να προσφέρουν πραγματική ενίσχυση στη λήψη αποφάσεων.

6.9 Μετρίασμός των Αρνητικών Συνεπειών

Υπάρχει μεγάλος κίνδυνος οι εξηγήσεις να παραπλανήσουν ή να χρησιμοποιηθούν καταχρηστικά, είτε από κακόβουλους ανθρώπους είτε από μελλοντικούς υπερνοήμονες πράκτορες. Πειστικές αλλά λανθασμένες εξηγήσεις μπορούν να οδηγήσουν σε σοβαρά

σφάλματα και υπερβολική εμπιστοσύνη σε ανεπαρκείς αποφάσεις, κάτι που μπορεί να αποδειχθεί ιδιαίτερα επικίνδυνο σε κρίσιμους τομείς όπως η υγεία. Για την αποτροπή αυτών των φαινομένων απαιτείται η θέσπιση αυστηρών κριτηρίων διαφεισιμότητας, η διασφάλιση ακρίβειας και λογοδοσίας, καθώς και η ενσωμάτωση της ΧΑΙ σε ένα ευρύτερο σύνολο εργαλείων ασφάλειας.

Κομβικό ρόλο διαδραματίζουν οι στρατηγικές ανίχνευσης αποτυχημένων ή ανακριβών εξηγήσεων, καθώς και ο περιορισμός της υποστήριξής τους όταν αυτή κρίνεται επιζήμια για τους χρήστες. Η ασφάλεια των εξηγήσεων γίνεται ακόμη πιο σημαντική όσο αυξάνεται η πολυπλοκότητα και η ικανότητα των συστημάτων ΤΝ. Σε σενάρια με υπερνοήμονες πράκτορες, η ανθρώπινη κατανόηση ενδέχεται να είναι ανεπαρκής, ενώ η μονομερής εμπιστοσύνη στην εξηγησιμότητα ως μέσο ασφάλειας διατρέχει σοβαρούς κινδύνους, καθώς προηγμένα συστήματα ΤΝ θα μπορούσαν να εκμεταλλευτούν τα όρια της ανθρώπινης αντίληψης. Συνεπώς, η εξηγησιμότητα θα πρέπει να συνδυάζεται με άλλα εργαλεία ασφάλειας στο πλαίσιο μιας ολοκληρωμένης στρατηγικής, ενώ απαιτείται ιδιαίτερη προσοχή στον σχεδιασμό ισχυρών συστημάτων ώστε να διασφαλιστεί η ευθυγράμμισή τους με τις ανθρώπινες αξίες.

6.10 Ενίσχυση του Κοινωνικού Αντίκτυπου

Ζητήματα όπως η απόδοση πρωτοτυπίας και η ανίχνευση λογοκλοπής σε δεδομένα που παράγονται από γενετικά μοντέλα, το δικαίωμα στη λήθη, και η ισορροπία δύναμης μεταξύ ατόμων και εταιρειών, υπογραμμίζουν τη σημασία της διαφάνειας και της λογοδοσίας στην εποχή της τεχνητής νοημοσύνης. Η ΧΑΙ μπορεί να συμβάλλει ουσιαστικά, διευκολύνοντας τον εντοπισμό της προέλευσης και της αυθεντικότητας των παραγόμενων δεδομένων μέσω τεχνικών όπως τα υδατογραφήματα, ενώ παράλληλα ενισχύει την προστασία της ιδιωτικότητας μέσω μηχανισμών ελέγχου και διαφανών επεξηγήσεων για τη χρήση προσωπικών δεδομένων.

Επιπλέον, η αντιμετώπιση της ανισορροπίας ισχύος δεν επιτυγχάνεται μόνο με διαφάνεια, αλλά απαιτεί συμμετοχικό σχεδιασμό και ενεργή εμπλοκή των χρηστών στις αποφάσεις που τους αφορούν. Η κατανόηση ή η αμφισβήτηση μιας αυτόματης απόφασης πρέπει να συνοδεύεται από αποτελεσματικούς μηχανισμούς ελέγχου, δικαιολογημένες διαδικασίες και ουσιαστικές εγγυήσεις κατά των διακρίσεων ή της χειραγώγησης. Η ΧΑΙ ενδυναμώνει τα άτομα, προσφέροντας τα κατάλληλα εργαλεία για κατανόηση, έλεγχο και ενεργή συμμετοχή, συμβάλλοντας στη διαφάνεια, τη δικαιοσύνη και τη συλλογική ευθύνη στον ψηφιακό κόσμο.

6.11 Επένδυση στην ΧΑΙ: Πυξίδα για την Πλοήγηση στο

Μέλλον

Παρόλο που το ενδιαφέρον για την Εξηγήσιμη Τεχνητή Νοημοσύνη αυξάνεται ραγδαία, η τεχνολογία αυτή εξακολουθεί να βρίσκεται σε αρχικό στάδιο υιοθέτησης. Όπως συνέβη και με άλλες μεγάλες καινοτομίες στην ιστορία όπως ο ηλεκτρισμός, που αν και ανακαλύφθηκε το 1873, χρειάστηκε σχεδόν μισό αιώνα για να φτάσει σε μαζική αποδοχή, η πλήρης διείσδυση της ΧΑΙ απαιτεί χρόνο, ανάπτυξη υποδομών και θεσμική εμπιστοσύνη. Η ιστορία της τεχνητής νοημοσύνης το αποδεικνύει, καθώς από το 1956 και το πρώτο πρόγραμμα ΑΙ, η πρόοδος πέρασε μέσα από κύκλους στασιμότητας, ώσπου να επιταχυνθεί στη σημερινή «χρυσή εποχή» χάρη στην αυξημένη υπολογιστική ισχύ και τη μείωση του κόστους αποθήκευσης που επέτρεψαν τη μαζική υιοθέτηση εφαρμογών. Όπως έχει δείξει το χρονοδιάγραμμα όλων των εμβληματικών εφευρέσεων, κάθε τεχνολογική επανάσταση χρειάζεται τον χρόνο της για να εξελιχθεί και να αλλάξει πραγματικά τον κόσμο.

Η Εξηγήσιμη Τεχνητή Νοημοσύνη αναμένεται να αναπτυχθεί παράλληλα με την ευρύτερη ΑΙ, αποκτώντας όμως πιο εξειδικευμένο χαρακτήρα. Η αρχική της υιοθέτηση θα ξεκινήσει κυρίως από τομείς όπου η διαφάνεια και η εμπιστοσύνη είναι κρίσιμες, όπως η υγειονομική περίθαλψη και οι χρηματοπιστωτικές υπηρεσίες. Σταδιακά, καθώς θα αναδεικνύεται η προστιθέμενη αξία της και θα μειώνεται το κόστος εφαρμογής, η ΧΑΙ θα επεκτείνεται σε ολοένα και περισσότερους τομείς. Η ανάγκη για άμεση υιοθέτηση της ΧΑΙ καθορίζεται κυρίως από δύο παράγοντες, το επίπεδο τεχνολογικής εξάρτησης και την κρισιμότητα των αποφάσεων σε κάθε οργανισμό. Εταιρείες με υψηλή τεχνολογική εξάρτηση και κρίσιμες λειτουργίες, όπως νοσοκομεία ή αυτόνομα οχήματα, πρέπει να ενσωματώσουν άμεσα τη ΧΑΙ, ενώ τεχνολογικά προηγμένες επιχειρήσεις όπως η Google και η Amazon θα ενισχύσουν περαιτέρω την εμπιστοσύνη των χρηστών μέσω της χρήσης της. Αντίθετα, εταιρείες με χαμηλότερη τεχνολογική εξάρτηση μπορούν προς το παρόν να παρακολουθούν την εξέλιξή της και να προετοιμάζονται για μια μελλοντική υιοθέτηση.

6.12 Η Συνεργασία ως Κλειδί

Η συνεργασία ως επιστημονική κοινότητα αποτελεί το θεμέλιο για την ανάπτυξη καλύτερης και πιο αξιόπιστης Εξηγήσιμης Τεχνητής Νοημοσύνης. Όταν πληθώρα επιστημόνων και ειδικών από διαφορετικά πεδία συνεργάζονται από κοινού, ανταλλάσσουν ιδέες, αξιοποιούν τη διαφορετική τεχνογνωσία τους και σέβονται ο ένας το έργο του άλλου, το τελικό αποτέλεσμα είναι πιο ολοκληρωμένο, αξιόπιστο και ουσιαστικό. Η ομαδική συνεργασία διευκολύνει την ανίχνευση λαθών (διαψευσιμότητα), την παραγωγή νέας γνώσης και την επιθυμία για περαιτέρω συμμετοχή της επιστημονικής κοινότητας. Έτσι, οικοδομούνται συλλογικά καλύτερα συστήματα τεχνητής νοημοσύνης, που λειτουργούν πραγματικά προς όφελος του ανθρώπου και της κοινωνίας.

7. Σύνοψη και Συμπέρασμα

7.1 Σύνοψη

Αρχικά, όπως προκύπτει από τη μελέτη αυτή, το φαινόμενο της αδιαφάνειας στα σύγχρονα αλγοριθμικά συστήματα ενισχύει την ανάγκη για την ενσωμάτωση της εξηγήσιμης τεχνητής νοημοσύνης, καθώς όλο και περισσότερες κρίσιμες αποφάσεις μεταβιβάζονται από τους ανθρώπους σε «μαύρα κουτιά» αλγορίθμων. Η παρούσα εργασία παρουσιάζει το θεωρητικό υπόβαθρο της Τεχνητής Νοημοσύνης, της Μηχανικής και της Βαθιάς Μάθησης, εστιάζοντας στη μετάβαση προς την ερμηνευσιμότητα και τη σημασία της για την αξιοπιστία και την κοινωνική αποδοχή των συστημάτων. Ιδιαίτερη έμφαση δίνεται στη διάκριση μεταξύ διαφανών, model-agnostic και model-specific τεχνικών ΧΑΙ, όπως LIME, SHAP, Grad-CAM, καθώς και στις μεθόδους counterfactual (MACE, MOCE, Polyjuice), που προσφέρουν νέες προοπτικές στην επεξήγηση αλγοριθμικών αποφάσεων.

Στη συνέχεια, εξετάζεται η ενοποιημένη πλατφόρμα Omni ΧΑΙ, η οποία τυποποιεί τα δεδομένα και αυτοματοποιεί την επιλογή και την εφαρμογή των κατάλληλων εξηγήσεων. Παρουσιάζεται επίσης το πείραμα “Δυνατότητα Προσομοίωσης”, όπου οι χρήστες αξιολόγησαν πέντε μεθόδους ΧΑΙ σε δοκιμές forward και counterfactual simulation, αναδεικνύοντας την αποτελεσματικότητα του LIME στα δομημένα δεδομένα και του Prototype σε κείμενα και πίνακες. Τα αποτελέσματα που προέκυψαν, καταδεικνύουν ότι η υποκειμενική ικανοποίηση δεν αποτελεί αξιόπιστο δείκτη κατανόησης, υπογραμμίζοντας την ανάγκη για αντικειμενικές μετρικές, όπως η simulatability και η causability.

Ακολουθούν πραγματικά παραδείγματα εφαρμογής της ΧΑΙ, κυρίως σε τομείς υψηλής ευθύνης όπως η υγειονομική περίθαλψη, το μάρκετινγκ, η εκπαίδευση, η ανίχνευση απάτης και η συμμόρφωση με ρυθμιστικό πλαίσιο, όπου η διαφάνεια και η λογοδοσία αποτελούν θεμελιώδεις προϋποθέσεις για την αποδοχή και την αποτελεσματικότητα της τεχνητής νοημοσύνης. Στη μελέτη αυτή προτείνονται, επίσης, μελλοντικές κατευθύνσεις για την περαιτέρω ανάπτυξη της ΧΑΙ, οι οποίες περιλαμβάνουν την εξήγηση μεγάλων γλωσσικών μοντέλων και τη βελτίωση των μεθόδων αξιολόγησης, μέχρι και την υιοθέτηση πολυδιάστατης ερμηνευσιμότητας που εστιάζει στη δικαιοσύνη, την ασφάλεια και τη λογοδοσία, δίνοντας πάντα προτεραιότητα στον άνθρωπο και στη διεπιστημονική συνεργασία.

Συνολικά, η εργασία αυτή προτείνει μια ολιστική αρχιτεκτονική ΧΑΙ, η οποία συνδυάζει αιτιατά μοντέλα, γενετικές βελτιστοποιήσεις και μηχανιστική ερμηνευσιμότητα σε μια ενιαία ροή εργασιών. Παράλληλα, θεμελιώνει αντικειμενικές μετρικές αξιολόγησης (simulatability, causability) και προτείνει πρακτικές κατευθύνσεις για μια πιο ασφαλή, δίκαιη και ανθρωποκεντρική υιοθέτηση της τεχνητής νοημοσύνης, με στόχο τη μέγιστη αξιοπιστία, χρηστικότητα και κοινωνική αποδοχή των έξυπνων συστημάτων στο μέλλον.

7.2 Συμπέρασμα

Συμπερασματικά, η εξηγήσιμη τεχνητή νοημοσύνη αναδεικνύεται ως ο θεμελιώδης καταλύτης μετάβασης της σύγχρονης τεχνητής νοημοσύνης από την εντυπωσιακή, αλλά συχνά αδιαφανή, απόδοση προς πιο πραγματικά αξιόπιστες και κοινωνικά αποδεκτές λύσεις. Η παρούσα μελέτη ανέδειξε ότι η διαφάνεια δεν αποτελεί επιλογή αλλά αναγκαιότητα. Όπως τα δεδομένα έχουν καταστεί το πολύτιμο καύσιμο στη νέα ψηφιακή εποχή, έτσι και η ανάγκη για διαφάνεια και ερμηνευσιμότητα αναδεικνύεται καθοριστική για την αξιοποίηση της τεχνητής νοημοσύνης σε πεδία υψηλού ρίσκου όπως η υγεία, η δικαιοσύνη, τα οικονομικά και η ασφάλεια. Η ΧΑΙ γεφυρώνει το χάσμα μεταξύ της υπολογιστικής ισχύος των συστημάτων και της ανθρώπινης κρίσης, προσφέροντας τεκμηριωμένες εξηγήσεις που ενισχύουν τη λογοδοσία, τη συμμόρφωση και κυρίως την εμπιστοσύνη.

Η μελέτη αυτή κατέδειξε επίσης ότι οι πολυτροπικές και πολυδιάστατες εφαρμογές της ΤΝ απαιτούν ενοποιημένες πλατφόρμες ερμηνευσιμότητας, όπως το τετραεπίπεδο οικοσύστημα της Omni ΧΑΙ, που συνδυάζει διαφανή και αδιαφανή μοντέλα, όπως τεχνικές model-agnostic, model-specific και μεθόδους counterfactual, επιτρέποντας τη συγκριτική ανάλυση και την παραγωγή πολυτροπικών εξηγήσεων σε ένα ενιαίο περιβάλλον. Η αντικειμενική αξιολόγηση παραμένει πρόκληση, καθώς τα πειράματα simulatability έδειξαν ότι η υποκειμενική ικανοποίηση του χρήστη δεν αποτελεί πάντα αξιόπιστο δείκτη πραγματικής κατανόησης. Η χρήση μετρικών όπως simulatability και causability, που εστιάζουν στην ανθρώπινη δυνατότητα πρόβλεψης της συμπεριφοράς του συστήματος, προτείνει ένα πιο αξιόπιστο και ανθρωποκεντρικό πλαίσιο αποτίμησης.

Σημαντική θέση έχει πλέον η συνεργασία ανθρώπου και μηχανής, με τη ΧΑΙ να θέτει τα θεμέλια για αμοιβαία κατανόηση και έλεγχο. Όπως ανέφερε το παράδειγμα του σκακιού, τα υβριδικά σχήματα αλγοριθμικής ανάλυσης με ανθρώπινη εποπτεία υπερτερούν τόσο των αποκλειστικά αυτόματων όσο και των ανθρωποκεντρικών λύσεων. Η ΧΑΙ θεμελιώνει αυτή τη συνέργεια, παρέχοντας αμοιβαία κατανόηση και έλεγχο. Παράλληλα, η πορεία προς τη μαζική υιοθέτηση της ΧΑΙ είναι σταδιακή αλλά αμετάκλητη, καθώς το ρυθμιστικό πλαίσιο (GDPR, AI Act) και οι αυξανόμενες κοινωνικές απαιτήσεις για λογοδοσία καθιστούν την εξηγησιμότητα σύντομα προαπαιτούμενη για κάθε κρίσιμη εφαρμογή τεχνητής νοημοσύνης.

Με βάση τα παραπάνω, διατυπώνονται διάφορες κατευθυντήριες προτάσεις, όπως η Ενσωμάτωση της ΧΑΙ από τον σχεδιασμό (ΧΑΙ-by-design), ώστε τα συστήματα να δημιουργούνται εξ αρχής με μηχανισμούς διαφάνειας και ελέγχου να υιοθετούν πολυδιάστατες μετρικές που συνυπολογίζουν δικαιοσύνη, ασφάλεια και λογοδοσία, αποφεύγοντας τις μονοδιάστατες αξιολογήσεις. Η επένδυση, επιπλέον, σε διεπιστημονικές ομάδες όπου ερευνητές μηχανικής μάθησης, ειδικοί HCI, νομικοί και κοινωνικοί επιστήμονες συνεργάζονται για να διασφαλίσουν ότι οι εξηγήσεις είναι τεχνικά ακριβείς και χρήσιμες για τους ανθρώπους, είναι ιδιαίτερα σημαντική.

Επίσης, προτείνεται η μετάβαση από τη συσχέτιση στην αιτιότητα, καθώς η ευρύτερη ενσωμάτωση αιτιακών γραφικών μοντέλων και counterfactual reasoning θα αυξήσει την εφαρμόσιμη αξία των εξηγήσεων, επιτρέποντας στους χρήστες να κατανοούν όχι μόνο «τι» προβλέπει το μοντέλο, αλλά και «τι χρειάζεται να αλλάξει» για να προκύψει ένα εναλλακτικό αποτέλεσμα. Η διάχυση της γνώσης μέσα από ανοιχτά πρότυπα, δημόσια benchmark datasets και εργαλεία ανοιχτού κώδικα, όπως το Omni XAI, θα μειώσει το φράγμα υιοθέτησης και θα επιταχύνει τον ρυθμό καινοτομίας στον τομέα.

Σε τελική ανάλυση, η XAI δεν αποτελεί απλώς τεχνική επιλογή αλλά προϋπόθεση κοινωνικής συναίνεσης για μια πιο ευρεία αξιοποίηση της τεχνητής νοημοσύνης. Η επιτυχία της εξαρτάται λιγότερο από την τεχνολογική πρόοδο και περισσότερο από την ικανότητά μας να οικοδομήσουμε ένα αξιόπιστο αφήγημα που θα ενισχύει, θα προστατεύει και θα ενδυναμώνει όλους τους εμπλεκόμενους. Η παρούσα εργασία στοχεύει να συμβάλλει σε αυτή την κατεύθυνση, προσφέροντας ένα συνεκτικό θεωρητικό πλαίσιο αλλά και πρακτικές κατευθύνσεις για την επόμενη γενιά υπεύθυνων, διαφανών και ανθρωποκεντρικών συστημάτων τεχνητής νοημοσύνης.

8. Βιβλιογραφία

Arsenault, P.-D., Wang, S., & Patenaude, J.-M. (2025). A Survey of Explainable Artificial Intelligence (XAI) in Financial Time Series Forecasting. *ACM Computing Surveys*. <https://doi.org/10.1145/3729531>

Barredo Arrieta, A., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., Garcia, S., Gil-Lopez, S., Molina, D., Benjamins, R., Chatila, R., & Herrera, F. (2020). Explainable Artificial Intelligence (XAI): Concepts, taxonomies,

Opportunities and Challenges toward Responsible AI. *Information Fusion*, 58(1), 82–115. <https://doi.org/10.1016/j.inffus.2019.12.012>

Bhatia, S., Mittal, V., & Sabharwal, S. (2024). *Building Trust and Transparency in AI: A Review of Explainable AI and its Ethical Implications*. 650–655. <https://doi.org/10.1109/emergin63207.2024.10961081>

Chou, Y.-L., Moreira, C., Bruza, P., Ouyang, C., & Jorge, J. (2021). Counterfactuals and causability in explainable artificial intelligence: Theory, algorithms, and applications. *Information Fusion*. <https://doi.org/10.1016/j.inffus.2021.11.003>

Dandl, S., Molnar, C., Binder, M., & Bischl, B. (2020). Multi-Objective Counterfactual Explanations. *Parallel Problem Solving from Nature – PPSN XVI*, 448–469. https://doi.org/10.1007/978-3-030-58112-1_31

Dhurandhar, A., Chen, P.-Y., Luss, R., Tu, C.-C., Ting, P., Shanmugam, K., & Das, P. (2018). Explanations based on the Missing: Towards Contrastive Explanations with Pertinent Negatives. *ArXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.1802.07623>

Doshi-Velez, F., & Kim, B. (2017). Towards A Rigorous Science of Interpretable Machine Learning. *ArXiv (Cornell University)*, 2. <https://doi.org/10.48550/arxiv.1702.08608>

Ertel, W. (2024). Introduction to Artificial Intelligence. In *Undergraduate topics in computer science*. <https://doi.org/10.1007/978-3-658-43102-0>

Finn, C., Xu, K., & Levine, S. (2018). Probabilistic Model-Agnostic Meta-Learning. *Advances in Neural Information Processing Systems*, 31.

<https://proceedings.neurips.cc/paper/2018/hash/8e2c381d4dd04f1c55093f22c59c3a08-Abstract.html>

Fragiadakis, G., Diou, C., Kousiouris, G., & Nikolaidou, M. (2024). Evaluating Human-AI Collaboration: A Review and Methodological Framework. *ArXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.2407.19098>

Hase, P., & Bansal, M. (2020). Evaluating Explainable AI: Which Algorithmic Explanations Help Users Predict Model Behavior? Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. <https://doi.org/10.18653/v1/2020.acl-main.491>

Hase, P., Bansal, M., Clark, P., & Wiegrefe, S. (2024). The Unreasonable Effectiveness of Easy Training Data for Hard Tasks. *ArXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.2401.06751>

Holzinger, A., Langs, G., Denk, H., Zatloukal, K., & Müller, H. (2019). Causability and explainability of artificial intelligence in medicine. *WIREs Data Mining and Knowledge Discovery*, 9(4). <https://doi.org/10.1002/widm.1312>

Kaplan, J., McCandlish, S., Henighan, T., Brown, T. B., Chess, B., Child, R., Gray, S., Radford, A., Wu, J., & Amodei, D. (2020, January 22). *Scaling Laws for Neural Language Models*. ArXiv.org. <https://doi.org/10.48550/arXiv.2001.08361>

Karimi, A.-H., Barthe, G., Balle, B., & Valera, I. (2019). Model-Agnostic Counterfactual Explanations for Consequential Decisions. *ArXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.1905.11190>

Korteling, J. E. (Hans)., van de Boer-Visschedijk, G. C., Blankendaal, R. A. M., Boonekamp, R. C., & Eikelboom, A. R. (2021). Human- versus Artificial Intelligence.

Frontiers in Artificial Intelligence, 4(2624-8212).

<https://doi.org/10.3389/frai.2021.622364>

Longo, L., Brcic, M., Cabitza, F., Choi, J., Confalonieri, R., Del Ser, J., Guidotti, R., Hayashi, Y., Herrera, F., Holzinger, A., Jiang, R., Khosravi, H., Lecue, F., Malgieri, G., Páez, A., Samek, W., Schneider, J., Speith, T., & Stumpf, S. (2024). Explainable Artificial Intelligence (XAI) 2.0: A Manifesto of Open Challenges and Interdisciplinary Research Directions. *Information Fusion*, 106, 102301.

<https://doi.org/10.1016/j.inffus.2024.102301>

Mothilal, R. K., Sharma, A., & Tan, C. (2020). Explaining machine learning classifiers through diverse counterfactual explanations. *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency*.

<https://doi.org/10.1145/3351095.3372850>

Nguyen, A., Yosinski, J., & Clune, J. (2015, June 1). *Deep neural networks are easily fooled: High confidence predictions for unrecognizable images*. IEEE Xplore.

<https://doi.org/10.1109/CVPR.2015.7298640>

Rai, A. (2020). Explainable AI: from Black Box to Glass Box. *Journal of the Academy of Marketing Science*, 48(1), 137–141. [https://doi.org/10.1007/s11747-](https://doi.org/10.1007/s11747-019-00710-5)

[019-00710-5](https://doi.org/10.1007/s11747-019-00710-5)

Rai, D., Zhou, Y., Feng, S., Saparov, A., & Yao, Z. (2024). A Practical Review of Mechanistic Interpretability for Transformer-Based Language Models. *ArXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.2407.02646>

Ramon, Y., Martens, D., Provost, F., & Evgeniou, T. (2020). A comparison of instance-level counterfactual explanation algorithms for behavioral and textual data:

SEDC, LIME-C and SHAP-C. *Advances in Data Analysis and Classification*.

<https://doi.org/10.1007/s11634-020-00418-3>

Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why Should I Trust You?": Explaining the Predictions of Any Classifier.

<https://doi.org/10.48550/arxiv.1602.04938>

Rudin, C. (2019). Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead. *Nature Machine Intelligence*, 1(5), 206–215. <https://doi.org/10.1038/s42256-019-0048-x>

Russell, S. J. (2020). *Human compatible : artificial intelligence and the problem of control*. Penguin Books.

Sandu, M. G., & Trăuşan-Matu, Ş. (2022). Comparing model-agnostic and model-specific XAI methods in Natural Language Processing. *RoCHI - International Conference on Human-Computer Interaction*, 115–118.

<https://doi.org/10.37789/rochi.2022.1.1.19>

Shinde, P. P., & Shah, S. (2018, August 1). *A Review of Machine Learning and Deep Learning Applications*. IEEE Xplore.

<https://doi.org/10.1109/ICCUBE.2018.8697857>

Tjoa, E., & Guan, C. (2020). A Survey on Explainable Artificial Intelligence (XAI): Toward Medical XAI. *IEEE Transactions on Neural Networks and Learning Systems*, 32(11), 1–21. <https://doi.org/10.1109/tnnls.2020.3027314>

Vilone, G., & Longo, L. (2021). Notions of explainability and evaluation approaches for explainable artificial intelligence. *Information Fusion*, 76, 89–106.

<https://doi.org/10.1016/j.inffus.2021.05.009>

Visani, G., Bagli, E., & Chesani, F. (2020). OptiLIME: Optimized LIME Explanations for Diagnostic Computer Algorithms. *ArXiv (Cornell University)*.
<https://doi.org/10.48550/arxiv.2006.05714>

Wachter, S., Mittelstadt, B., & Russell, C. (2017). Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR. *ArXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.1711.00399>

Wang, D., Churchill, E., Maes, P., Fan, X., Shneiderman, B., Shi, Y., & Wang, Q. (2020). From Human-Human Collaboration to Human-AI Collaboration. *Extended Abstracts of the 2020 CHI Conference on Human Factors in Computing Systems*.
<https://doi.org/10.1145/3334480.3381069>

Wexler, J., Pushkarna, M., Bolukbasi, T., Wattenberg, M., Viegas, F., & Wilson, J. (2019). The What-If Tool: Interactive Probing of Machine Learning Models. *IEEE Transactions on Visualization and Computer Graphics*, 1–1.
<https://doi.org/10.1109/tvcg.2019.2934619>

Wu, T., Marco Tulio Ribeiro, Heer, J., & Weld, D. S. (2021). *Polyjuice: Generating Counterfactuals for Explaining, Evaluating, and Improving Models*.
<https://doi.org/10.18653/v1/2021.acl-long.523>

Yang, W., Le, H., Laud, T., Savarese, S., & Hoi, S. C. H. (2022, December 12). *OmniXAI: A Library for Explainable AI*. ArXiv.org.
<https://doi.org/10.48550/arXiv.2206.01612>

Yu, H. Q., Alaba, A., & Eziefuna, E. (2024). Evaluation of Integrated XAI Frameworks for Explaining Disease Prediction Models in Healthcare. *Communications*

in Computer and Information Science, 14–28. https://doi.org/10.1007/978-3-031-52216-1_2